



SAPIENZA
UNIVERSITÀ DI ROMA

Progettazione e Sviluppo di una Piattaforma Full Stack per l'Annotazione di Narrative Complottiste tramite Crowdsourcing

Facoltà di Ingegneria dell'Informazione, Informatica e Statistica
Laurea Triennale in Informatica

Matteo Pasquale Geusa

Matricola 2058638

Relatore

Prof. Matteo Cinelli

Correlatore

Prof. Mattia Samory

Anno Accademico 2025/2026

Tesi non ancora discussa

**Progettazione e Sviluppo di una Piattaforma Full Stack per l'Annotazione di
Narrative Complotte tramite Crowdsourcing**

Tesi di Laurea Triennale. Sapienza Università di Roma

© 2026 Matteo Pasquale Geusa. Tutti i diritti riservati

Questa tesi è stata composta con L^AT_EX e la classe Sapthesis.

Email dell'autore: matteogeusa03@gmail.com

Dedicato a me, di qualche anno fa.

Sommario

Molti compiti di annotazione testuale non si limitano a classificare un documento, ma chiedono di individuare i confini delle porzioni di testo che esprimono un concetto, porzioni che spesso si sovrappongono. Raccogliere questo tipo di annotazione in crowdsourcing richiede oggi di comporre più strumenti indipendenti, e quelli esistenti trattano la sovrapposizione degli span come un'estensione del formato dei dati o come una funzione per annotatori esperti, non come un'esperienza progettata per chi annota per la prima volta.

Questa tesi presenta la progettazione e lo sviluppo di una piattaforma full stack open source per l'annotazione in crowdsourcing di narrative complottiste, nata dal caso di studio PsyCoMark, il Task 10 di SemEval-2026. La piattaforma offre un'interfaccia in cui gli span sovrapposti si definiscono direttamente sul testo e integra in un'unica configurazione l'intero ciclo dello studio, dall'ingresso dei partecipanti tramite Prolific a un percorso di preparazione configurabile, alla distribuzione dei documenti, fino al controllo qualità con documenti a soluzione nota e alla stima della competenza degli annotatori con MACE.

Il sistema è stato valutato con un cognitive walkthrough condotto insieme a una ricercatrice tra gli organizzatori di PsyCoMark. La sessione indica che l'integrazione del ciclo risponde a un bisogno reale dei ricercatori, ha portato a riorganizzare la configurazione del progetto e ha mostrato che la sovrapposizione degli span pone problemi di interazione specifici. Il vantaggio dell'interfaccia rispetto agli strumenti esistenti resta da verificare con uno studio su annotatori reali.

Indice

1	Introduzione	1
1.1	Motivazione	1
1.2	Il gap	2
1.3	Il problema affrontato	2
1.4	Novità	2
1.5	Contributo	2
1.6	Implicazioni	3
1.7	Struttura della tesi	3
2	Background e lavori correlati	5
2.1	Il caso di studio, PsyCoMark	5
2.2	Gli strumenti di annotazione esistenti	5
2.3	Controllo della qualità nel crowdsourcing	6
2.4	Che cosa manca	6
3	Dati, materiali e definizioni	7
3.1	Il progetto come unità di configurazione	7
3.2	Formalizzazione del task di annotazione	8
3.3	Lo schema di annotazione	9
3.4	Formato del dataset	10
3.5	Le gold unit	10
3.6	Annotatore e partecipazione al progetto	11
4	Metodi	13
4.1	L'interazione di annotazione	13
4.2	L'ingresso nel progetto	15
4.3	Amministrazione del task live	19
4.4	Configurazione del task	23
4.5	Architettura del sistema	25
5	Risultati	27
5.1	La valutazione con un'esperta di dominio	27
5.1.1	Perché un cognitive walkthrough, e con chi	27
5.1.2	Cosa è emerso	28
5.1.3	Cosa ha convinto	30
5.1.4	In sintesi	31

6	Discussione	33
6.1	Il lato del ricercatore	33
6.2	Il lato dell'annotatore	34
6.3	Cosa significa per il gap	34
6.4	In sintesi	35
7	Limitazioni e sviluppi futuri	37
7.1	Una sola valutatrice, in una sessione guidata	37
7.2	Chi ha valutato non è chi annota	37
7.3	Un solo caso di studio	38
7.4	Sviluppi futuri	38
8	Conclusioni	41
	Bibliografia	43
	Ringraziamenti	45

Capitolo 1

Introduzione

1.1 Motivazione

Per spiegare perché un commento sia complottista non basta un’etichetta sull’intero testo. Bisogna individuare chi viene accusato, cosa gli viene attribuito, chi ne sarebbe danneggiato e quali prove vengono citate, e ciascuno di questi elementi occupa una porzione diversa del testo. Il compito di stabilire i confini di queste porzioni prende il nome di unitizing (Krippendorff et al. 2016), e compare in una famiglia crescente di task, dall’estrazione di entità annidate (Finkel e Manning 2009) all’analisi del sentiment per aspetti (Zhang et al. 2023), fino all’argument mining (Stab e Gurevych 2017). In molti di questi task le porzioni si sovrappongono, perché la stessa frase può nominare l’attore di un complotto ed essere al tempo stesso parte dell’azione che gli viene attribuita.

PsyCoMark, il Task 10 di SemEval-2026 (Samory, Soldner e Batzdorfer 2026), è un esempio concreto di questa difficoltà. Il compito chiede di individuare in commenti Reddit cinque marcatori psicolinguistici delle narrative complottiste, i cui span possono sovrapporsi, e le annotazioni sono state raccolte in crowdsourcing da lavoratori reclutati online. L’accordo tra annotatori misurato sugli span è di 0,15 valore ottenuto dal rapporto tra l’effettiva sovrapposizione delle porzioni di testo selezionate dagli annotatori e il totale degli span evidenziati. Se il valore fosse pari a 1, significherebbe che vi è una concordanza perfetta, con tutti gli annotatori che hanno individuato esattamente i medesimi confini iniziali e finali per ogni marcatore. Mentre un punteggio così basso indica una forte discrepanza nelle selezioni, con sovrapposizioni solo parziali o assenti. Questo rappresenta quindi la prova evidente che individuare i confini esatti delle unità di testo è un compito intrinsecamente più ambiguo e complesso rispetto all’assegnazione di una singola etichetta all’intero documento.

Secondo la prospettiva prospettivista, per costrutti soggettivi come quelli coinvolti nelle narrative complottiste una parte del disaccordo tra annotatori può riflettere letture diverse e legittime dello stesso testo (Cabitza, Campagner e Basile 2023). Per distinguere queste differenze dagli errori serve però che l’annotazione venga raccolta in condizioni controllate, con annotatori preparati, un’interfaccia che non introduca errori propri e strumenti per stimare l’affidabilità di ciascuno.

Condurre uno studio di questo tipo in crowdsourcing richiede oggi di assemblare

più strumenti indipendenti. Uno serve per il reclutamento, uno per il consenso informato e i questionari, uno per l'annotazione e un altro ancora per analizzare l'affidabilità dei dati raccolti. Il ricercatore deve tenerli sincronizzati, gestire a mano il passaggio dei dati dall'uno all'altro e, se lavora con altri colleghi, trovare un modo per condividere lo stesso studio.

1.2 Il gap

Tra gli strumenti di annotazione disponibili, molti sanno rappresentare span sovrapposti. Lo fanno però trattando la sovrapposizione come un'estensione del formato dei dati, un'opzione da abilitare oppure una funzione pensata per annotatori esperti. Nessuno di essi documenta come rendere la sovrapposizione gestibile da chi annota per la prima volta, cioè da un lavoratore reclutato su una piattaforma di crowdsourcing senza addestramento specifico. Il capitolo 2 esamina questi strumenti nel dettaglio.

1.3 Il problema affrontato

La tesi affronta quindi una domanda precisa. Come si può progettare un sistema che permetta a un ricercatore di condurre uno studio di unitizing con span sovrapposti in crowdsourcing, dalla preparazione degli annotatori alla stima dell'affidabilità, e che offra a chi annota un'interazione pensata per questo compito?

1.4 Novità

La proposta centrale è un'interfaccia di annotazione interattiva in cui gli span sovrapposti si definiscono direttamente sul testo, senza ricorrere a formati intermedi o a procedure manuali. L'interfaccia aggancia la selezione ai confini delle parole, così da eliminare le selezioni a metà parola, e mantiene leggibili le etichette anche quando più span coprono la stessa porzione di testo. Selezionare una porzione già annotata aggiunge un nuovo span senza toccare quelli esistenti.

1.5 Contributo

L'interfaccia fa parte di un sistema open source che integra l'intero ciclo di uno studio di annotazione in crowdsourcing in un'unica applicazione. Il sistema gestisce l'ingresso dei partecipanti da Prolific, un percorso di preparazione configurabile fatto di consenso informato, questionario, codebook, istruzioni e task di prova, la distribuzione dei documenti tra gli annotatori secondo strategie diverse, il controllo della qualità tramite documenti con soluzione nota e la stima della competenza degli annotatori con MACE (Hovy et al. 2013). Tutte queste fasi condividono la stessa configurazione del progetto, e più ricercatori possono lavorare sullo stesso studio con permessi distinti. Il sistema è stato valutato con una sessione di cognitive walkthrough condotta insieme a una ricercatrice tra gli organizzatori di PsyCoMark.

1.6 Implicazioni

Un sistema che colmasse questo gap ridurrebbe, per chi annota, la parte di disaccordo dovuta all'interfaccia, rendendo più facile separare gli errori dalle letture legittimamente diverse. Per chi conduce lo studio eliminerebbe il lavoro di raccordo tra strumenti, che richiede competenze tecniche estranee alla domanda di ricerca, e renderebbe gli studi di unitizing accessibili anche a gruppi che oggi non hanno le risorse per costruirsi un'infrastruttura propria.

1.7 Struttura della tesi

Il capitolo 2 presenta il caso di studio, gli strumenti di annotazione esistenti e gli approcci al controllo qualità nel crowdsourcing. Il capitolo 3 definisce i concetti su cui si basa il sistema, dal progetto allo schema di annotazione, alle gold unit. Il capitolo 4 descrive come il sistema realizza questi concetti, seguendo il percorso dell'annotatore e quello del ricercatore. Il capitolo 5 riporta la valutazione condotta con un'esperta di dominio, il capitolo 6 ne discute il significato rispetto al problema di partenza e il capitolo 7 ne descrive i limiti e gli sviluppi possibili. Il capitolo 8 riassume i messaggi principali del lavoro.

Capitolo 2

Background e lavori correlati

Questo capitolo chiarisce il problema affrontato dalla tesi prima di parlare della soluzione. Parte dal caso di studio che l'ha originato, cioè l'annotazione di marcatori psicolinguistici in commenti complottisti, passa agli strumenti di annotazione esistenti e a come trattano gli span sovrapposti, e chiude con gli approcci al controllo della qualità nel crowdsourcing.

2.1 Il caso di studio, PsyCoMark

PsyCoMark, il Task 10 di SemEval-2026 (Samory, Soldner e Batzdorfer 2026), chiede di estrarre da commenti Reddit cinque marcatori psicolinguistici radicati nella psicologia evoluzionistica e poi di classificare il contenuto come complottista o meno. I cinque marcatori sono Actor, cioè le entità cui viene attribuito il complotto, Action, le attività ingannevoli attribuite ai cospiratori, Threat (nel paper *Effect*), le conseguenze o il danno prodotti, Victim, chi ne è colpito, ed Evidence, le prove addotte a sostegno della credenza. Il corpus raccoglie 5.354 commenti da 226 subreddit, scelti in modo da mescolare comunità dichiaratamente complottiste e comunità ordinarie, così che i marcatori non coincidano con l'argomento della discussione.

Gli span dei marcatori possono sovrapporsi, perché un documento può contenere più span per ciascun marcatore e questi possono intersecarsi tra loro (Samory, Soldner e Batzdorfer 2026). L'annotazione, inoltre, è stata condotta in crowdsourcing, con 138 lavoratori reclutati su Prolific e un percorso fatto di consenso informato, questionario preliminare, istruzioni con codebook, task di addestramento e infine dieci documenti da annotare. Sono queste due caratteristiche a guidare il resto della tesi.

2.2 Gli strumenti di annotazione esistenti

Gli strumenti generalisti per l'annotazione testuale sono molti, e una rassegna sistematica li ha confrontati usando tra i criteri anche la possibilità di sovrapporre span (Neves e Ševa 2021). Questa sezione guarda come i più diffusi trattano la sovrapposizione e per quale tipo di utente sono progettati.

Potato è open source ed è esplicitamente pensato per il crowdsourcing, perché prevede l'ingresso degli annotatori tramite Prolific, e nelle versioni recenti gestisce

gli span sovrapposti impilando le fasce, ma accumula le etichette nel punto di intersezione, dove coprono il testo (Pei et al. 2022). Prodigy è commerciale e supporta in modo nativo span sovrapposti e annidati, ma si rivolge a sviluppatori e a chi costruisce dataset in prima persona, non a lavoratori reclutati su una piattaforma (Montani e Honnibal 2018). doccano è open source e permette la sovrapposizione solo se il ricercatore attiva un'apposita opzione, disattivata per impostazione predefinita (Nakayama et al. 2018). INCEpTION, rivolto ad annotatori esperti in contesti accademici, rende la sovrapposizione una proprietà configurabile per ciascun livello di annotazione, anch'essa disattivata di default (Klie et al. 2018). Label Studio dichiara il supporto agli span sovrapposti nei propri modelli di progetto, ma distribuisce anche un componente aggiuntivo il cui scopo è segnalare un errore e bloccare l'invio quando due span si sovrappongono (Tkachenko et al. 2020).

La sovrapposizione è quindi rappresentabile quasi ovunque, ma resta un'eccezione da abilitare oppure una funzione rivolta a chi annota per mestiere. Nessuno di questi strumenti documenta il lato dell'annotatore occasionale, cioè quante etichette restino leggibili quando si accumulano sulla stessa porzione di testo, cosa accada al testo sottostante e come si selezionino o si rimuova uno span coperto da altri. Questa è la condizione di chi annota in crowdsourcing senza addestramento specifico, ed è il contesto in cui PsyCoMark ha raccolto i suoi dati.

2.3 Controllo della qualità nel crowdsourcing

Un'annotazione raccolta da persone non addestrate richiede anche di stimarne l'affidabilità. In letteratura ricorrono due approcci. Il primo consiste nell'inserire nel flusso di lavoro documenti con soluzione nota, contro cui confrontare le risposte. Il secondo stima congiuntamente l'etichetta corretta e la competenza di ciascun annotatore a partire dalle sole annotazioni raccolte, senza soluzioni note, ed è l'approccio di MACE (Hovy et al. 2013). I due si completano, perché il primo misura pochi casi in modo diretto mentre il secondo sfrutta l'intero volume raccolto, ed entrambi sono ripresi nel capitolo 4.

2.4 Che cosa manca

PsyCoMark è un esempio di task in cui le unità da annotare si sovrappongono e vengono raccolte da annotatori non specializzati. Gli strumenti di annotazione esistenti sanno rappresentare la sovrapposizione, ma la trattano come un'opzione da abilitare o la rivolgono a utenti esperti, e nessuno documenta come renderla gestibile da chi annota per la prima volta. Il sistema descritto nei capitoli seguenti si colloca in questo spazio.

Capitolo 3

Dati, materiali e definizioni

Il capitolo parte dal progetto, cioè l'unità che raccoglie ogni aspetto di uno studio di annotazione, e procede verso le sue parti. Descrive cosa produce una singola istanza di annotazione, cosa ne vincola la forma, quali dati la alimentano, come si misura la qualità delle risposte raccolte e chi le produce.

3.1 Il progetto come unità di configurazione

Ogni studio di annotazione nasce da un progetto, l'oggetto che raccoglie in un unico posto le scelte che lo definiscono, cioè chi lo cura, cosa va annotato e come, chi annota e come si verifica la qualità delle risposte.

Un progetto riunisce in un'unica configurazione il dataset da annotare (§3.4), lo schema di annotazione che vincola la forma di ogni istanza (§3.3), il flusso di onboarding dei partecipanti (§3.6), il controllo qualità tramite gold unit (§3.5), e le modalità di distribuzione dei documenti sul bacino di annotatori.




Figura 3.1. Transizione degli stati di un progetto

Un progetto attraversa quattro stati nel corso della sua vita, cioè bozza, attivo, in pausa e completato (Figura 3.1), e accetta nuove istanze di annotazione solo quando è attivo. In bozza è modificabile liberamente in ogni suo aspetto. Per attivarlo serve almeno un documento nel dataset. Un progetto attivo ma non ancora pubblicato ufficialmente funziona da ambiente di prova, in cui il ricercatore può verificare la configurazione (§4.3). Quando poi il progetto viene pubblicato ufficialmente, la

configurazione si blocca, schema compreso, e da quel momento si può cambiare solo clonando il progetto. Il blocco serve a mantenere confrontabili le annotazioni, che non lo sarebbero più se lo schema o i criteri di distribuzione cambiassero a raccolta già avviata.

Chi cura un progetto ha un ruolo distinto da chi vi partecipa. Il ricercatore crea il progetto e può aggiungere altri collaboratori per condividerne la gestione. L'annotatore, di cui si occupa il resto del capitolo, non configura il progetto ma vi partecipa.

Le sezioni seguenti riprendono uno per uno gli elementi che il progetto raccoglie, prima l'unità di lavoro che l'annotatore produce, poi cosa ne vincola la forma, quali dati la alimentano, come si verifica la sua qualità, infine chi la produce.

3.2 Formalizzazione del task di annotazione

Classificare un testo assegna un'unica etichetta all'intero documento, senza indicare quale porzione la giustifica. Il task trattato in questa tesi chiede invece di individuare le porzioni di testo, dette *span*, che sostengono ciascuna etichetta, e permette che porzioni diverse si sovrappongano quando più interpretazioni convivono sullo stesso testo. Questo compito, noto in letteratura come *unitizing*, produce per ogni documento un'istanza di annotazione, cioè l'unità di lavoro assegnata a un singolo annotatore su un singolo documento. L'esempio seguente mostra un'istanza prodotta da un annotatore.

```
{
  "pid": "TESTER",
  "document": "8e9cf589-86d5-4874-aa8a-8b7f9b9998d8",
  "result": {
    "span_highlight": [
      {
        "start": 30,
        "end": 44,
        "label": "Actor",
        "text": "the government",
        "id": "span-1788854071889-118"
      },
      {
        "start": 45,
        "end": 70,
        "label": "Action",
        "text": "to control public opinion",
        "id": "span-1788854071889-119"
      },
      {
        "start": 27,
        "end": 70,
        "label": "Threat",
        "text": "by the government to control public opinion",
        "id": "span-1788854071889-120"
      }
    ]
  }
},
```

```

    "classification": "Yes"
  }
}

```

Un'istanza di annotazione contiene un insieme di span, ciascuno con un indice di inizio, un indice di fine e un'etichetta assegnata, come mostra il campo `span_highlight`, e, quando lo schema lo prevede, una o più etichette di classificazione a livello di documento, come mostra il campo `classification`.

Due span sono in overlap quando condividono almeno un carattere. In termini formali, dati due span $(start_1, end_1)$ e $(start_2, end_2)$, vale $start_1 < end_2$ e $start_2 < end_1$. Il task ammette la sovrapposizione perché la stessa porzione di testo può sostenere più interpretazioni distinte, indipendentemente dall'etichetta assegnata.

Span, overlap e istanza di annotazione mantengono questo significato in tutta la tesi.

3.3 Lo schema di annotazione

Lo schema di annotazione è uno dei campi della configurazione del progetto e vincola cosa deve produrre ogni istanza di annotazione, cioè quali componenti sono previsti e, per ciascuno, quali etichette o opzioni sono disponibili. È una struttura dichiarativa definita direttamente dal ricercatore.

Il sistema supporta due tipi di componenti. Il componente `span_highlight` definisce un insieme di etichette per l'annotazione di span. Ogni etichetta ha un nome e un colore obbligatori e un suggerimento testuale facoltativo, mostrato all'annotatore. Il componente `classification` definisce una domanda a scelta singola o multipla applicata all'intero documento. Un progetto può usare uno dei due componenti o entrambi.

L'esempio seguente definisce lo schema ibrido usato per le narrative complottiste. L'esempio precedente compila un'istanza su un documento specifico, mentre lo schema descrive le regole che ogni istanza del progetto deve rispettare, qualunque sia il documento. Per questo il formato cambia, da JSON con span e indici a una lista dichiarativa di etichette in YAML.

```

components:
- type: span_highlight
  labels:
  - name: Actor
    color: "#FF5733"
    hover_hint: "Who is allegedly responsible for a malicious action or agenda?"
  - name: Action
    color: "#33FF57"
    hover_hint: "What is the actor doing or planning to do to cause negative outcomes?"
  - name: Victim
    color: "#3357FF"
    hover_hint: "Who is negatively affected by the actor's agenda?"
  - name: Threat
    color: "#FF33F6"

```

```

    hover_hint: "What harm or negative consequences result from the
        actor's agenda?"
  - name: Evidence
    color: "#FFA500"
    hover_hint: "Which arguments or expressions does the writer of the
        text use to support his claims?"

- type: classification
  question: "Is this text related to a conspiracy theory?"
  multi_select: false
  options:
    - label: Conspiracy
      value: "Yes"
    - label: Not Conspiracy
      value: "No"
    - label: Ambiguous
      value: "Can't tell"

```

Ogni componente ha una specifica formale di campi obbligatori e facoltativi. Se manca un campo obbligatorio o ne compare uno non riconosciuto, lo schema non è valido e il sistema lo rifiuta al momento del caricamento.

Lo schema stabilisce la forma di ogni istanza di annotazione. La sezione seguente descrive cosa viene distribuito agli annotatori perché la producano.

3.4 Formato del dataset

Il dataset di un progetto è un unico file JSONL, senza divisione tra addestramento, validazione e test, in cui ogni riga rappresenta un documento in formato JSON.

Le chiavi che contengono il testo e l'identificativo del documento sono configurabili per progetto, perché non tutti i dataset usano gli stessi nomi di campo. Ogni altra chiave presente nella riga viene conservata come metadato del documento, per esempio il subreddit o l'id del thread di provenienza, come nell'esempio seguente.

```

{"id": "t1_abc123",
 "subreddit": "conspiracy",
 "text": "The moon landing was faked by the government to control public
  opinion."}

```

Il materiale annotato proviene da PsyCoMark, il dataset ufficiale del Task 10 di SemEval-2026 (Samory, Soldner e Batzdorfer 2026). Il corpus è composto da commenti Reddit raccolti in comunità eterogenee, dalla politica alle serie televisive. In questa tesi il dataset è usato in forma redatta, per tutelare la privacy degli autori dei commenti.

Alcune righe del dataset hanno una soluzione nota. Sono le gold unit, descritte nella sezione seguente.

3.5 Le gold unit

Una gold unit è una riga del dataset con soluzione nota, usata per misurare quanto le risposte di un annotatore si avvicinano a quella soluzione.

La soluzione, nel campo `gold_solution`, segue lo stesso schema di annotazione del progetto e può contenere un insieme di span, una classificazione o entrambi. Può anche essere parziale, per limitare la verifica a una parte della risposta. L'esempio seguente contiene sia la classificazione sia gli span.

```
{
  "text": "The moon landing was faked by the government to control public opinion.",
  "gold_solution": {
    "classification": "Yes",
    "span_highlight": [
      {
        "start": 30,
        "end": 44,
        "label": "Actor",
        "text": "the government"
      },
      {
        "start": 45,
        "end": 70,
        "label": "Action",
        "text": "to control public opinion"
      },
      {
        "start": 27,
        "end": 70,
        "label": "Threat",
        "text": "by the government to control public opinion"
      }
    ]
  }
}
```

Questo documento è lo stesso usato in §3.2 e in §3.4, così che istanza, riga del dataset e soluzione nota si possano confrontare sullo stesso testo.

3.6 Annotatore e partecipazione al progetto

Un annotatore è identificato da un identificativo esterno al sistema, in questo caso quello assegnato da Prolific, il servizio di reclutamento usato. Oltre a questo identificativo il sistema conserva solo alcuni metadati.

Lo stesso annotatore può partecipare a più progetti contemporaneamente, ciascuno con la propria selezione e i propri criteri di qualità. Per questo il sistema non tratta lo stato come una proprietà dell'annotatore, ma della sua partecipazione a un progetto specifico, rappresentata dalla coppia annotatore-progetto.

In questa coppia si registrano tre informazioni. La prima è lo stato di avanzamento (in attesa, attivo, escluso, completato). La seconda è il superamento delle fasi di onboarding, cioè i passaggi preparatori che precedono l'annotazione vera e propria, come il consenso informato, lo screening con le domande di eleggibilità e demografia, e il codebook, il materiale che spiega come interpretare il task. La terza sono le metriche di affidabilità calcolate sulle gold unit.

Lo stesso annotatore può quindi risultare attivo in un progetto ed escluso in un altro, perché l'affidabilità misurata dipende dal singolo studio.

Progetto, istanza di annotazione, schema, dataset, gold unit e annotatore sono i concetti che il capitolo Metodi riprende per descrivere come il sistema li realizza.

Capitolo 4

Metodi

Il capitolo 3 definisce gli elementi costitutivi dell'applicazione, cioè progetto, istanza di annotazione, schema, dataset, gold unit e annotatore. Questo capitolo descrive come il sistema li realizza, seguendo separatamente il percorso dell'annotatore e quello del ricercatore che amministra il task. Per ciascuno si parte dal momento centrale e si risale poi a ciò che lo prepara. Per l'annotatore si parte dall'interazione di annotazione, con l'overlap come contributo centrale (§4.1), e si risale all'ingresso nel progetto (§4.2). Per il ricercatore si parte dall'amministrazione del task mentre raccoglie dati (§4.3) e si risale alla sua configurazione (§4.4). L'ultima sezione descrive l'architettura del sistema (§4.5). Le schermate sono presentate nel punto in cui l'utente le incontra.

4.1 L'interazione di annotazione

Il percorso dell'annotatore parte dall'interfaccia di annotazione, perché è lì che nasce il dato che il resto del sistema prepara e controlla.

Ricevuto un documento (§4.4), l'annotatore lo affronta attraverso l'interfaccia di annotazione. I documenti arrivano uno alla volta. Quando l'annotatore invia la risposta, il sistema gli propone il successivo, finché la strategia di distribuzione (§4.4) non ha più documenti da assegnargli. A quel punto lo rimanda alla piattaforma di reclutamento con il codice di completamento. Nello stesso flusso arrivano anche le gold unit (§3.5), che l'interfaccia presenta come qualsiasi altro documento, così che l'annotatore non sappia quando viene controllato.

Il capitolo precedente ammette l'overlap tra span come proprietà del task (§3.2). Il sistema lo traduce in un'interazione diretta sul testo, e l'interfaccia con cui l'annotatore definisce gli span è il contributo centrale della tesi.

The interface is titled "HIGHLIGHTER" and features a top navigation bar with five tabs: Actor 1, Action 2, Victim 3, Threat 4, and Evidence 5. The main text area contains the following paragraph:

The moon landing was clearly faked. Look at the shadows in the photos, they don't match the sun's position. NASA has been lying to us for decades to hide the truth about the space dome.

Below the text, there is a section titled "Is this text related to a conspiracy theory?" with three radio button options: Conspiracy, Not Conspiracy, and Ambiguous.

Figura 4.1. L'interfaccia di annotazione aggancia automaticamente la selezione ai confini di parola.

La selezione avviene sul testo (Figura 4.1), con un aggancio automatico alla parola intera. Se la selezione dell'utente termina a metà parola o include spazi in eccesso, il sistema sposta i margini forzandoli ai confini della parola intera più vicina. Questo elimina le selezioni a metà parola, un errore comune nell'annotazione di span dovuto alla difficoltà di selezionare con il mouse esattamente i caratteri desiderati.

Gli strumenti esistenti sanno rappresentare l'overlap, ma lo rendono poco leggibile. Potato (Pei et al. 2022), per esempio, permette di selezionare span sovrapposti trascinando direttamente sul testo, ma accumula le etichette dei singoli span nel punto di intersezione, coprendo sia le etichette stesse sia il testo sottostante (Figura 4.2).

The interface is titled "Text to Annotate:" and shows a text area with the following text: "It's okay, no social." Above the text, there are three overlapping colored boxes representing spans: a black box labeled "Date", a red box labeled "Organization", and a yellow box labeled "Date".

Below the text area, there is a section titled "Select text spans and label them with the appropriate entity type" with five radio button options: Person, Organization, Location, Date (which is selected), and Product.

Figura 4.2. In Potato le etichette degli span sovrapposti si accumulano nel punto di intersezione e coprono il testo.

Nell'interfaccia proposta, selezionare una seconda volta una porzione di testo già annotata, con un'etichetta diversa, aggiunge un nuovo span senza rimuovere il precedente. Ogni span è reso con una fascia colorata, impilata sotto il testo in base al livello di sovrapposizione (Figura 4.3). L'annotatore vede subito quante etichette coprono ciascuna porzione di testo, senza doverlo ricostruire da una lista di coordinate.




Figura 4.3. Gli span sovrapposti sono resi visibili da una fascia colorata impilata per ciascuno.

Le etichette non sono sempre visibili. Compaiono solo al passaggio del mouse, e mostrano tutti gli span che coprono il punto sotto il cursore. Il testo resta così leggibile anche con molte sovrapposizioni, al contrario di quanto avviene in Potato, dove le etichette si accumulano sopra il testo nel punto di intersezione. Nella Figura 4.3 il cursore si trova sullo span che inizia con “NASA”, ed è per questo che solo la sua etichetta è visibile.

Accanto all'etichetta che compare al passaggio del mouse c'è un pulsante che rimuove quello span. I confini di uno span già creato non si modificano. Per correggerlo lo si rimuove e lo si ridefinisce con una nuova selezione. L'etichetta da applicare si sceglie dai pulsanti colorati sopra il testo oppure dalla tastiera, perché ogni pulsante riporta il numero che lo richiama, così che un annotatore che lavora su molti documenti non debba spostare la mano sul mouse per cambiare etichetta.

L'interfaccia non è cablata su un task predefinito. Ogni componente dello schema (§3.3) corrisponde a un blocco visivo generato dinamicamente, uno per `span_highlight`, uno per `classification`, assemblato in base ai componenti presenti nello schema del progetto. Aggiungere un nuovo tipo di componente al sistema significa aggiungere un nuovo blocco, senza modificare quelli esistenti.

Con questa interfaccia l'annotatore definisce span sovrapposti direttamente sul testo. La sezione seguente descrive i passaggi che lo portano fin qui, mentre §4.3 spiega come la sua risposta viene misurata.

4.2 L'ingresso nel progetto

Un annotatore che si iscrive a un progetto non riceve subito documenti da annotare. Prima attraversa una pipeline di onboarding (§3.6), cioè la sequenza di fasi introdotta nel capitolo precedente, che il sistema implementa come una macchina a stati.




Figura 4.4. Le fasi della pipeline di onboarding, ciascuna attivabile o disattivabile in configurazione.

Ogni fase, riportata in Figura 4.4, ha un interruttore indipendente nella configurazione del progetto. Un progetto minimale può disattivarle tutte e portare l’annotatore direttamente all’annotazione, mentre uno studio più esigente le attiva tutte, compreso l’obbligo di superare un task di pratica prima di procedere. In entrambi i casi la sequenza è gestita dallo stesso motore, e cambia solo la configurazione.

Il contenuto di ogni fase è definito dal ricercatore, non cablato nel sistema. Lo screening è una lista di domande configurabile, caricata come file YAML o JSON, con tipi di risposta diversi (testo, numero, scelta singola o multipla) e domande obbligatorie o facoltative, utili non solo per eleggibilità e demografia di base ma anche per domande personalizzate specifiche dello studio. Codebook e istruzioni sono invece documenti liberi in Markdown, caricati allo stesso modo. La validazione dei file caricati è descritta in §4.4.

L’annotatore entra da un link che contiene il suo identificativo sulla piattaforma di reclutamento e quello del progetto. Se il progetto non è attivo, il sistema rifiuta la sessione. Altrimenti restituisce la fase da cui l’annotatore deve partire. L’avanzamento nella pipeline è registrato nell’iscrizione dell’annotatore (§3.6), non nel client. Un annotatore che torna a metà pipeline riprende da dove aveva lasciato.

La prima fase è il consenso informato. L’annotatore legge il testo preparato dal ricercatore e lo accetta prima di procedere (Figura 4.5).

Informed Consent

Please read the following information carefully before proceeding.

Informed Consent

Welcome to the Study

Thank you for participating in this research study. Please read the following information carefully before proceeding.

Your Task

You will be asked to read and classify a series of short texts. The estimated time to complete all tasks is approximately **15–20 minutes**. The goal of this study is to improve automated systems for analysing online discourse.

Your Data and Privacy

This task is **anonymous**. We do not collect any personally ident...

[Read the full consent form →](#)

☐ I have read and understood the information above.

I Agree

Figura 4.5. Il consenso informato, con il testo definito dal ricercatore, va accettato prima di proseguire.

Segue lo screening, con le domande definite dal ricercatore (Figura 4.6). Se manca una risposta obbligatoria, il server rifiuta l'invio.

About You

Please answer the following questions before starting the task.

1. How old are you? *

2. Gender? *

3. Native language? *

Continue

Figura 4.6. Il questionario di screening, con domande definite dal ricercatore per lo studio specifico.

Il codebook presenta il quadro teorico dello studio, per esempio le definizioni

delle categorie da annotare. L'annotatore lo legge e conferma di averlo fatto prima di passare alle istruzioni (Figura 4.7).




Figura 4.7. Il codebook presenta il quadro teorico dello studio, e l'annotatore conferma di averlo letto.

Le istruzioni spiegano come svolgere il task. Se il ricercatore lo prevede, sono seguite da un task di pratica. L'annotatore annota un testo di esempio con la stessa interfaccia della sezione precedente e riceve subito un riscontro (Figura 4.8). Per ogni span della soluzione vede se l'ha individuato, per la classificazione vede la risposta corretta, e può leggere i suggerimenti preparati dal ricercatore. Il confronto con la soluzione avviene nel browser e usa lo stesso criterio delle gold unit, descritto in §4.3. Se il task di pratica è obbligatorio, l'annotatore deve riprovare finché non risponde correttamente. Altrimenti può proseguire anche dopo un tentativo sbagliato.

PRACTICE TASK — Try annotating this example before starting the real task

Practice Task
Read the text below and complete the tasks, then submit to see feedback.

HOW TO ANNOTATE:
1 Highlight: Click & drag over text
2 Label: Click a colored button
3 Remove: Click an existing highlight

HIGHLIGHTER Actor 1 Action 2 Victim 3 Threat 4 Evidence 5

The government is putting chips in the water to control us and nobody seems to care about it.

Is this text related to a conspiracy theory?

☐ Conspiracy

☐ Not Conspiracy

☐ Ambiguous

Clear Skip Practice Submit Practice

Figura 4.8. Il riscontro sul task di pratica indica quali span della soluzione sono stati individuati.

Superato l'onboarding, l'annotatore riceve i documenti da annotare. Come il sistema li distribuisce è una scelta del ricercatore, descritta in §4.4. Con l'ingresso nel progetto si chiude il percorso dell'annotatore. Le prossime due sezioni cambiano prospettiva, dal lavoro dell'annotatore a quello del ricercatore che lo rende possibile. La prima descrive come il ricercatore sorveglia uno studio in corso, la seconda come lo configura senza scrivere codice.

4.3 Amministrazione del task live

Il sistema è pensato perché il ricercatore possa configurare e sorvegliare uno studio senza competenze tecniche, un obiettivo che vale sia in fase di configurazione iniziale sia oltre, quando lo studio è già in corso. Questa sezione parte dal secondo caso. Mentre gli annotatori lavorano, il ricercatore ha bisogno di sapere a che punto è la raccolta, se i dati sono di qualità sufficiente e come intervenire se qualcosa non va. Il punto di partenza è la dashboard del progetto (Figura 4.9).




Figura 4.9. La dashboard del progetto. I riquadri numerati indicano lo stato corrente (1), le transizioni disponibili (2), l'avanzamento della raccolta (3) e i conteggi di documenti, gold unit, annotatori e annotazioni (4).

Il primo strumento è lo stato del progetto, definito nel capitolo precedente (§3.1). La dashboard mostra lo stato corrente (1) e le transizioni disponibili (2). Lo stato decide cosa vedono gli annotatori. Solo un progetto attivo accetta sessioni e assegna documenti. Negli altri stati il sistema rifiuta le nuove sessioni, e chi sta annotando riceve un messaggio che avvisa che il progetto non accetta più annotazioni. Quando il progetto è attivo, il ricercatore può aprirlo dall'amministrazione come partecipante di prova e percorrere tutta la pipeline. Finché il progetto resta nell'ambiente di prova, cioè attivo ma non ancora pubblicato ufficialmente, tutte le sessioni vengono registrate come prova. Le annotazioni di prova sono conteggiate separatamente da quelle reali e non entrano nella valutazione sulle gold unit. Al momento della pubblicazione ufficiale il sistema cancella tutte le annotazioni e le iscrizioni raccolte fino a quel momento, e la raccolta reale parte da zero.

La dashboard riporta anche l'avanzamento della raccolta (3), calcolato sul numero


di annotazioni ricevute rispetto a quelle richieste dai documenti, insieme al numero di documenti, gold unit, annotatori iscritti e annotazioni raccolte (4).

Sullo stesso progetto possono lavorare più ricercatori (§3.1). Per questo il sistema tiene un registro delle attività, consultabile dalla scheda *Project Log Entries*, che riporta chi ha modificato il progetto, cosa ha cambiato e quando. Così ogni collaboratore può ricostruire le modifiche fatte dagli altri senza doverle chiedere.

Le risposte raccolte attraverso l'interfaccia descritta in §4.1 sono ciò che il sistema misura per stimare la qualità del lavoro di un annotatore. Tra i documenti distribuiti (§4.4) figurano anche le gold unit (§3.5). Il sistema le usa per misurare la qualità delle risposte raccolte, con due meccanismi complementari.

Il primo è l'iniezione periodica di gold unit nel flusso di documenti regolari, con una frequenza configurabile per ogni progetto. Quando un annotatore riceve una gold unit, la sua risposta viene confrontata con la soluzione nota componente per componente. La classificazione richiede corrispondenza esatta, mentre gli span richiedono che la soluzione trovi un corrispondente nella risposta dell'annotatore entro una tolleranza di cinque caratteri sui confini.

L'esito di ogni gold unit aggiorna l'accuratezza cumulata dell'annotatore su quel progetto specifico. La decisione di escludere un annotatore è delegata a una strategia di valutazione, isolata dal resto del sistema, che esclude l'annotatore quando l'accuratezza scende sotto una certa soglia configurabile, dopo un numero minimo di gold unit completate. Un annotatore escluso non riceve più documenti e viene avvisato dell'esclusione. La separazione tra meccanismo di iniezione e criterio di esclusione lascia aperta la possibilità di modificare il criterio senza toccare il resto della pipeline di controllo qualità. Il ricercatore vede per ogni iscrizione l'accuratezza raggiunta e lo stato dell'annotatore (Figura 4.10).



Annotator	Type	Project	Status	Gold Tasks Completed	Gold Accuracy	MACE Score	Exclude from distribution	Created at
☐ 4c91d5fa7682b0a5f930aa1	Worker	Conspiracy Narrative Detection - Wave 1	ACTIVE	3	67%	0.05	☒	Sept. 20, 2026, 2:28 p.m.
☐ 3b80c4e936571af194e82099	Worker	Conspiracy Narrative Detection - Wave 1	EXCLUDED	4	50%	0.33	☒	Sept. 20, 2026, 2:28 p.m.
☐ 2a79b3d825460f083d71088	Worker	Conspiracy Narrative Detection - Wave 1	COMPLETED	5	80%	0.43	☒	Sept. 20, 2026, 2:28 p.m.
☐ 1f68a2c714359edf72c60077	Worker	Conspiracy Narrative Detection - Wave 1	COMPLETED	5	80%	0.46	☒	Sept. 20, 2026, 2:28 p.m.
☐ 0e571fb603248dce61b5f066	Worker	Conspiracy Narrative Detection - Wave 1	ACTIVE	4	75%	0.26	☒	Sept. 20, 2026, 2:28 p.m.
☐ 9d46e0a5f2137cbd50a4e055	Worker	Conspiracy Narrative Detection - Wave 1	COMPLETED	5	80%	0.79	☒	Sept. 20, 2026, 2:28 p.m.
☐ 8c35d9f4e1026bac49f3d044	Worker	Conspiracy Narrative Detection - Wave 1	ACTIVE	5	80%	0.67	☒	Sept. 20, 2026, 2:28 p.m.
☐ 7b24c8e3d0f15a9b38e2c033	Worker	Conspiracy Narrative Detection - Wave 1	COMPLETED	5	100%	0.95	☒	Sept. 20, 2026, 2:28 p.m.
☐ 6a13b7d2c9e04f8a27d1b022	Worker	Conspiracy Narrative Detection - Wave 1	COMPLETED	5	80%	0.84	☒	Sept. 20, 2026, 2:28 p.m.
☐ 5f2a91c4e8b07a3d19c4e011	Worker	Conspiracy Narrative Detection - Wave 1	COMPLETED	5	100%	0.83	☒	Sept. 20, 2026, 2:28 p.m.

10 Enrollments & Assignments

Figura 4.10. Per ogni iscrizione il ricercatore vede accuratezza sulle gold unit, stato e punteggio MACE.

Il secondo meccanismo nasce da un limite del primo. Le gold unit coprono solo una piccola parte del dataset, quindi dicono come si comporta un annotatore su

pochi documenti scelti, non su tutto il lavoro che svolge nello studio. Per avere un quadro completo la piattaforma integra MACE (Multi-Annotator Competence Estimation) (Hovy et al. 2013), un modello probabilistico che stima quanto ci si può fidare di ogni annotatore guardando solo le annotazioni raccolte, senza conoscere le risposte giuste.

Prendiamo l'esempio di un insegnante che deve correggere un quiz di cui ha perso le soluzioni. Può comunque confrontare le risposte degli studenti tra loro, ma un semplice voto di maggioranza non basta, perché tratterebbe allo stesso modo chi ha studiato e chi tira a indovinare. MACE risolve il problema facendo un'ipotesi esplicita su come nasce ogni annotazione. Davanti a un documento, un annotatore può lavorare con attenzione, e in quel caso riporta l'etichetta corretta, oppure rispondere senza considerare il contenuto, e in quel caso sceglie un'etichetta secondo una sua abitudine personale, per esempio selezionando quasi sempre la stessa opzione. Ogni annotatore è quindi descritto da due quantità. La prima è la sua competenza, cioè la probabilità che una sua risposta sia data con attenzione. La seconda è la sua abitudine, cioè quali etichette tende a scegliere quando risponde a caso. Questa distinzione è importante, perché una risposta casuale può coincidere con quella corretta anche solo per fortuna, e il modello ne tiene conto.

Né le etichette corrette né le competenze sono note in partenza, e MACE le stima insieme alternando due passi. Si parte da valori iniziali scelti a caso per competenze e abitudini. Nel primo passo, usando questi valori, il modello stima per ogni documento quale etichetta è più probabile, dando più peso alle risposte degli annotatori ritenuti più competenti. Nel secondo passo usa le etichette appena stimate per correggere i valori degli annotatori. Chi ha dato spesso l'etichetta ritenuta corretta, e non per un'abitudine che lo porterebbe comunque a sceglierla, vede crescere la sua competenza, mentre chi se ne discosta la vede diminuire. I due passi si ripetono finché le stime smettono di cambiare in modo significativo. Poiché il punto di arrivo può dipendere dai valori iniziali, l'intera procedura viene ripetuta più volte da punti di partenza diversi, e si tiene il risultato che spiega meglio le annotazioni osservate.

La piattaforma usa la variante bayesiana di questa procedura, pensata per un problema tipico del crowdsourcing. Un annotatore che ha lavorato su pochi documenti e li ha azzeccati tutti sembrerebbe perfetto, ma potrebbe essere stato solo fortunato. La variante bayesiana parte dal presupposto che ogni annotatore abbia una competenza intermedia e si sposta da questa ipotesi solo man mano che le annotazioni si accumulano, come se a quelle reali si aggiungessero alcune risposte fittizie nella media. Con pochi dati il punteggio resta quindi prudente, con molti dati riflette davvero il comportamento dell'annotatore.

Il ricercatore avvia il calcolo dalla console di amministrazione su un progetto e ottiene due risultati, entrambi prodotti dall'ultimo giro della procedura. Il primo è, per ogni documento, l'etichetta più probabile con la relativa confidenza. Il modello assegna a ciascuna etichetta possibile una probabilità, combinando le risposte ricevute in modo che quella di un annotatore competente sposti molto il risultato e quella di un annotatore che risponde spesso a caso lo sposti poco. L'etichetta stimata è quella con la probabilità più alta, e la confidenza è proprio questa probabilità. È alta quando gli annotatori affidabili concordano, bassa quando si dividono o quando a rispondere sono stati soprattutto annotatori poco affidabili.

Il secondo risultato, quello su cui si basa la valutazione degli annotatori, è il punteggio di competenza. Per ciascuna risposta di un annotatore il modello stima la probabilità che sia stata data con attenzione, cioè che coincida con l'etichetta ritenuta corretta e che la coincidenza non sia spiegabile con la sua abitudine. Il punteggio è la media di queste probabilità su tutti i documenti che l'annotatore ha visto, corretta dalla prudenza della variante bayesiana, e va da 0 a 1. Viene salvato sull'iscrizione dell'annotatore al progetto (§3.6) e compare accanto all'accuratezza sulle gold unit (Figura 4.10). A differenza di quest'ultima, tiene conto di tutto il lavoro svolto nello studio e permette di valutare anche chi ha incontrato poche gold unit o nessuna.

MACE ha però un perimetro preciso. Tutto il ragionamento presuppone che ogni annotatore scelga un'etichetta da una lista per un intero documento. Con gli span questo non vale, perché due annotatori possono evidenziare porzioni di testo che si sovrappongono solo in parte e non esiste un'unica risposta da confrontare. Il calcolo è quindi disponibile solo per i progetti di classificazione, mentre in quelli con span la qualità resta affidata alle gold unit. Dove si applica, i due meccanismi si completano, perché le gold unit offrono un controllo esatto su pochi casi e MACE una valutazione estesa a tutto lo studio.

Gold unit e MACE misurano la qualità di ciò che gli annotatori producono. Se invece è la configurazione dello studio a dover cambiare durante la raccolta, il ricercatore deve tenere conto di un vincolo. Una volta pubblicato ufficialmente un progetto, la sua configurazione e il suo dataset non sono più modificabili, così che tutti gli annotatori lavorino nelle stesse condizioni.

Per modificare un campo di un progetto già pubblicato, il ricercatore può duplicarlo in tre modalità, così da iterare rapidamente su varianti dello studio senza ricostruire la configurazione da zero. La prima copia solo la configurazione, la seconda anche il dataset completo. La terza copia la configurazione insieme alle gold unit, ai documenti che non hanno ancora raggiunto il numero minimo di annotazioni e agli annotatori non esclusi e non ancora completati, di cui vengono azzerate le metriche sulle gold unit. La copia parte sempre in bozza e non pubblicata.

Stati, soglie di esclusione e parametri di distribuzione che il ricercatore osserva durante la raccolta vengono però decisi prima del lancio. La sezione seguente descrive come.

4.4 Configurazione del task

Prima che un progetto raccolga dati, il ricercatore ne definisce ogni aspetto. L'intera configurazione descritta in questo capitolo, schema, dataset, pipeline di onboarding, strategia di distribuzione, controllo qualità, è esposta attraverso un'amministrazione Django estesa, organizzata in dieci schede tematiche, cioè Project Details, Dataset Upload, Annotation Schema, Informed Consent, Screening Setup, Codebook Setup, Instruction, Practice Task, Quality & Monitoring e Distribution (Figura 4.11).

Figura 4.11. La configurazione del progetto è divisa in schede tematiche, una per ogni aspetto dello studio.

Schema, screening, codebook e istruzioni si caricano come file YAML, JSON o Markdown. Lo schema viene validato nella sua struttura e rifiutato se non conforme, il task di pratica viene bloccato se la sua soluzione non è compatibile con lo schema, mentre lo screening viene solo letto come YAML o JSON e i testi in Markdown vengono salvati così come sono. Un errore nello schema o nel task di pratica viene quindi segnalato prima che il progetto possa essere pubblicato, non scoperto a raccolta dati in corso.

Una volta che un annotatore ha superato l'onboarding (§4.2), il sistema deve decidere quali documenti assegnargli. Lo fa secondo una di tre strategie, selezionabile per progetto. La strategia standard assegna documenti in modo casuale, entro una soglia minima e massima di annotazioni per documento. La strategia a piena sovrapposizione espone a ogni annotatore l'intero dataset, per studi che richiedono la massima ridondanza. La strategia a blocchi con annotatori fissi divide il dataset in blocchi di dimensione configurabile e assegna ciascun blocco a un numero fisso di annotatori, con una ridondanza controllata. È utile quando si vuole misurare il livello di accordo tra un gruppo chiuso di annotatori sugli stessi documenti.

L'assegnazione può coinvolgere più annotatori che richiedono un documento nello stesso istante. Per questo avviene sotto lock a livello di record nel database. Il documento somministrato resta bloccato per tutta la durata della transazione, così che due richieste concorrenti non ricevano mai lo stesso documento.

Una volta distribuiti, i documenti includono anche le gold unit (§3.5). Il ricercatore le carica nella stessa amministrazione e fissa i parametri del controllo qualità descritto in §4.3, cioè ogni quanti documenti iniettarne una, l'accuratezza minima richiesta e il numero di gold unit dopo cui la valutazione comincia.

Configurazione e amministrazione sono le parti del sistema con cui lavora il ricercatore. L'ultima sezione del capitolo descrive l'architettura su cui si appoggiano.

4.5 Architettura del sistema

Interfaccia di annotazione (§4.1) e amministrazione (§4.3, §4.4) sono le due parti del sistema usate rispettivamente dall'annotatore e dal ricercatore. Il sistema è composto da un backend Django, che espone un'API REST e la console di amministrazione, e da un frontend Vue 3 single page, che implementa l'interfaccia di annotazione. I due componenti vengono eseguiti in container Docker separati, con PostgreSQL come base dati. Il deploy dell'intero sistema avviene con un unico comando Docker Compose, per non richiedere al ricercatore competenze di configurazione infrastrutturale.




Figura 4.12. Il backend espone due piani separati, configurazione per il ricercatore ed esecuzione per l'annotatore, entrambi alimentati dallo stesso schema di annotazione.

L'architettura, schematizzata in Figura 4.12, separa due piani. Il piano di configurazione è esposto tramite la dashboard di amministrazione Django ed è rivolto al ricercatore e ai suoi collaboratori. Il piano di esecuzione è esposto tramite API REST ed è rivolto all'annotatore. Configurare un'annotazione e svolgerla richiedono competenze e permessi diversi, per questo i due piani restano separati. Entrambi però dipendono dallo schema di annotazione del progetto (§3.3), che alimenta sia la validazione lato configurazione sia la generazione dell'interfaccia lato esecuzione. Così un cambiamento allo schema si riflette su entrambi senza sincronizzazione manuale.

Con l'architettura si chiude la descrizione di come il sistema realizza i concetti del capitolo 3. Il capitolo Risultati riporta come il sistema si è comportato quando è

stato usato da una ricercatrice.

Capitolo 5

Risultati

5.1 La valutazione con un'esperta di dominio

Un ricercatore che prepara uno studio di annotazione non legge il codice, ma attraversa l'interfaccia una schermata alla volta e decide cosa fare in base a quello che vede. Un'etichetta ambigua o un'opzione nel posto sbagliato possono portare a un progetto configurato male, oppure a un'azione irreversibile compiuta senza volerlo. In uno studio in crowdsourcing un errore di configurazione di solito emerge solo quando la raccolta è finita, cioè quando gli annotatori sono già stati pagati. Nel caso peggiore i dati vanno scartati, nel migliore sono di qualità più bassa del previsto. Per osservare questi problemi serve una persona che usi il sistema. Questa sezione racconta la sessione condotta con una ricercatrice che conosce il problema dall'interno, cosa ne è emerso e come il sistema è cambiato di conseguenza.

5.1.1 Perché un cognitive walkthrough, e con chi

Il metodo scelto è il cognitive walkthrough (Wharton et al. 1994), una tecnica di ispezione dell'usabilità pensata per chi usa un sistema per la prima volta. Il valutatore percorre una sequenza di task realistici e, per ogni passo, si chiede se l'utente capirebbe cosa deve fare, se troverebbe il comando giusto, se ne interpreterebbe correttamente l'etichetta e se, dopo averlo usato, si accorgerebbe di aver ottenuto l'effetto voluto. Il metodo si adatta bene a una piattaforma come questa, dove la maggior parte delle difficoltà nasce dal primo contatto, quando chi configura un progetto deve orientarsi tra molte opzioni senza ancora conoscere le regole del sistema. Si adatta anche perché il task è già ben definito e le modalità di interazione sono ormai consolidate in strumenti simili. Il ricercatore che configura uno studio è un professionista che conosce già il compito e non ha bisogno di impararlo, quindi ciò che resta da valutare è se l'interfaccia gli permette di capire come svolgerlo.

La sessione si è svolta il 16 aprile 2026, da remoto, ed è durata circa un'ora e mezza. La partecipante è Veronika Batzdorfer, tra gli organizzatori di PsyCoMark (Samory, Soldner e Batzdorfer 2026), quindi una persona che ha già condotto in prima persona uno studio di annotazione in crowdsourcing simile a quello che la piattaforma vuole supportare. Non aveva mai usato l'interfaccia, ma conosceva a fondo i concetti su cui si basa, perché è tra gli autori del paper che ha introdotto PsyCoMark (Samory, Soldner e Batzdorfer 2026). Questo la rendeva una valutatrice

particolarmente adatta, in grado di giudicare se l'interfaccia rispecchiasse davvero la logica del compito di annotazione.

La traccia della sessione comprendeva sette task, che coprono l'intero ciclo di vita di un progetto.

1. Creare un nuovo progetto.
2. Caricare il dataset da annotare.
3. Portare il progetto nell'ambiente di prova.
4. Simulare un partecipante e completare un'annotazione di prova.
5. Cancellare i dati di prova senza alterare le configurazioni del progetto.
6. Lanciare ufficialmente il progetto.
7. Correggere un errore nella configurazione di un progetto già lanciato.

Rispetto alla forma classica del metodo, la sessione ha preso una piega più guidata. Ero io l'intervistatore a condividere lo schermo e a muoversi nell'interfaccia seguendo la traccia, mentre la partecipante osservava, commentava ad alta voce e interrompeva con domande ogni volta che qualcosa non le era chiaro. Questa scelta riduce la possibilità di osservare dove l'utente si perde da solo, ma in cambio ha lasciato spazio a domande che la traccia non prevedeva, e alcune di queste si sono rivelate le più utili. Della sessione esiste una registrazione video e degli appunti, che sono stati rivisti e integrati con le osservazioni del relatore per produrre il resoconto che segue.

5.1.2 Cosa è emerso

Le osservazioni si raccolgono in quattro gruppi. I primi due riguardano problemi veri e propri, cioè la struttura della configurazione e la chiarezza di un'etichetta. Il terzo riguarda le azioni irreversibili, su cui la partecipante ha fatto diverse domande e ha trovato un vincolo che il sistema comunica solo dopo l'errore. L'ultimo raccoglie un'esigenza che il sistema non copriva.

Il caricamento del dataset.

Il primo ostacolo è comparso già nei task iniziali. All'epoca la configurazione era divisa in sei schede, ma alcune raccoglievano più aspetti diversi. La scheda *Annotation schema & Dataset upload* metteva insieme lo schema di annotazione e il caricamento dei documenti, e il campo per il file del dataset compariva solo in fondo, dopo l'intero schema in YAML (Figura 5.1, a sinistra). Chi arrivava sulla scheda vedeva lo schema e non il punto in cui caricare i dati. La partecipante si è fermata su questo passaggio e ha capito dove fosse il campo solo quando la pagina è stata scorsa fino in fondo.

La configurazione è stata quindi riorganizzata in dieci schede, una per ciascun aspetto del progetto. Le funzionalità sono rimaste le stesse, ma sono state ridistribuite seguendo il modo in cui un ricercatore pensa al proprio esperimento, una fase dopo l'altra. Il caricamento del dataset ha ora una scheda propria, separata dallo schema

(Figura 5.1, a destra), e lo stesso è avvenuto per le schede che univano più passaggi dell'onboarding, divise in consenso informato, screening, codebook, istruzioni e task di prova. Ogni campo è ora visibile senza scorrere, e le schede seguono l'ordine in cui il progetto viene configurato.

(a) Prima della sessione. Schema e dataset nella stessa scheda, con il caricamento dei documenti in fondo.

(b) Dopo la sessione. Il caricamento del dataset ha una scheda dedicata.

Figura 5.1. La configurazione del progetto prima e dopo il cognitive walkthrough.

L'etichetta del pulsante *Clear*.

Durante l'annotazione di prova, mentre selezionava gli span, la partecipante ha chiesto se esistesse un modo per tornare indietro. Il sistema offre due strade, la X sul singolo span e un pulsante *Clear*, ma il pulsante l'ha lasciata in dubbio, perché non era chiaro se cancellasse l'ultimo span o tutti. Ha suggerito lei stessa di chiamarlo *Clear all*, e l'etichetta è stata cambiata in questo senso (Figura 5.2). Sull'assenza di una scorciatoia per annullare l'ultima azione ha invece osservato che non è un problema rilevante.

Le azioni irreversibili.

Il ciclo di vita del progetto è la parte in cui un errore costa di più, ed è quella in cui la partecipante si è fermata più spesso a chiedere. Vedendo il pulsante di lancio ufficiale, la prima domanda è stata cosa succede se si lancia per errore e si vuole togliere il progetto dalla rete. Un progetto lanciato può essere messo in pausa, e la risposta l'ha soddisfatta. Un secondo punto ha riguardato la cancellazione dei dati di prova, che richiede di riportare prima il progetto in bozza o in pausa. Il sistema lo comunica con un messaggio solo dopo che l'utente ha provato a cancellare, quindi la partecipante ha scoperto il vincolo per tentativi. Infine il blocco della configurazione dopo il lancio, affrontato nel task 7, è stato capito senza difficoltà. Il banner che spiega perché i campi non sono più modificabili e propone di clonare il progetto

The screenshot shows a web interface titled "Task Instruction" with the instruction: "Highlight the psycholinguistic markers, then select the overall classification." Below this is a "HIGHLIGHTER" section with five colored buttons: Actor (red), Action (blue), Effect (green), Victim (purple), and Evidence (orange). A text block is displayed with several spans highlighted in these colors. Below the text is a "Classify this text:" section with three buttons: "Conspiracy" (blue), "Not Conspiracy" (light blue), and "Ambiguous" (light blue). At the bottom are two buttons: "Clear All" and "Submit & Next".

Figura 5.2. L'interfaccia di annotazione dopo la sessione. Con più span sovrapposti sullo stesso testo, il pulsante in basso dichiara esplicitamente che rimuove tutte le annotazioni del documento.

(Figura 5.3) è risultato chiaro, e lo stesso vale per la differenza tra clonare solo la configurazione o anche documenti e annotatori.

Il tempo minimo per documento.

Fuori dalla traccia, guardando quanto velocemente si poteva completare un'annotazione di prova, la partecipante ha chiesto se fosse possibile imporre un tempo minimo per ogni documento, così da impedire che un partecipante clicchi a caso, completi il compito in pochi secondi e venga comunque pagato. È un problema concreto del crowdsourcing, che i meccanismi di controllo qualità descritti nel capitolo 4 affrontano solo a posteriori. Oggi il sistema registra il tempo impiegato per ogni annotazione e, nella vista amministrativa, evidenzia in rosso quelle completate in meno di cinque secondi, ma non impedisce l'invio.

5.1.3 Cosa ha convinto

Gli apprezzamenti si sono concentrati sulle parti che aiutano il ricercatore a controllare il proprio studio prima e durante la raccolta. La partecipante ha indicato come particolarmente utile l'ambiente di prova, che permette di attraversare il percorso da partecipante e verificare che la configurazione sia corretta prima di aprire il progetto al pubblico. Ha apprezzato la vista della singola annotazione, sia nella resa grafica sia nel formato grezzo, il calcolo dell'affidabilità degli annotatori, che ha definito *really handy*, e il registro delle attività, utile soprattutto quando sullo stesso progetto lavorano più ricercatori. Il giudizio complessivo è stato positivo, con un riferimento esplicito alla quantità di aspetti personalizzabili e alla loro sensatezza.

General		Project Members	Project Log Entries
Project Details Dataset Upload Annotation Schema Informed Consent Screening Setup Codebook Setup Instructions Practice Task			
Quality & Monitoring Distribution			
Official Project & Locked This configuration is sealed to ensure data integrity. To make structural changes, you must clone the project. CLONE PROJECT			
Project Details In this section you can edit the project name, slug (URL), and description.			
Name	[DEMO] Conspiracy Theory Detection Project name		
Slug	demo-live-conspiracy Unique Identifier for the URL (e.g., 'project-slug')		
Description	Active annotation campaign for detecting conspiracy theories in social media posts. Annotators highlight key spans and classify each post. Project description		

Figura 5.3. Un progetto lanciato ufficialmente. I campi sono in sola lettura e il banner spiega il motivo, proponendo la clonazione come via per apportare modifiche.

La partecipante ha però osservato che, per chi non ha mai visto la dashboard e la pipeline completa, le informazioni sono tante.

5.1.4 In sintesi

La sessione ha fatto emergere due problemi nella presentazione della configurazione, cioè il dataset nascosto in fondo a una scheda e un vincolo sulla cancellazione dei dati di prova che si scopre solo provando, oltre a un'etichetta ambigua nell'interfaccia di annotazione e a un'esigenza non coperta, il tempo minimo per documento. Il dataset e l'etichetta sono stati corretti dopo la sessione. Il blocco della configurazione dopo il lancio e la clonazione sono stati capiti senza aiuto, e la partecipante ha apprezzato soprattutto l'ambiente di prova, il calcolo dell'affidabilità e il registro delle attività. Il capitolo successivo riprende questi risultati per capire cosa dicono rispetto al problema da cui la tesi è partita.

Capitolo 6

Discussione

Il capitolo 5 ha riportato cosa è emerso dalla sessione con la ricercatrice. Questo capitolo ne ricava le risposte alla domanda posta nell'introduzione (§1.3). La domanda ha due metà, una rivolta al ricercatore che conduce lo studio e una a chi annota, e le prime due sezioni le affrontano una alla volta (§6.1 e §6.2). La terza (§6.3) guarda cosa significano insieme per il gap da cui la tesi parte.

6.1 Il lato del ricercatore

Integrare l'intero ciclo dello studio in un'unica configurazione risponde a un bisogno che chi ha condotto uno studio di questo tipo riconosce subito. Le funzioni che la partecipante ha indicato come più utili sono l'ambiente di prova, il calcolo dell'affidabilità e il registro delle attività (§5.1.3), e hanno in comune il fatto di stare tra una fase e l'altra dello studio. L'ambiente di prova attraversa consenso, screening, codebook, task di pratica e annotazione in un solo percorso. Il calcolo dell'affidabilità lavora sulle annotazioni raccolte senza bisogno di esportarle. Il registro tiene traccia delle modifiche quando più ricercatori lavorano sullo stesso progetto. Sono i punti in cui, componendo strumenti separati, il ricercatore deve costruirsi da solo il raccordo tra un passaggio e l'altro (§1.1).

Con l'integrazione, però, la complessità dello studio resta e si raccoglie in un'unica configurazione. Chi usa strumenti separati deve farli comunicare tra loro, mentre chi usa questo sistema deve capire una configurazione che descrive tutte le fasi insieme. Il dataset nascosto in fondo alla scheda dello schema e il commento sulla quantità di informazioni (§5.1.2) mostrano che questo costo si paga al primo contatto, quando il ricercatore si trova davanti all'intero studio in una volta sola.

Il blocco della configurazione dopo il lancio è un vincolo rigido, eppure è stato capito senza aiuto, perché il banner spiega perché esiste e propone la clonazione come alternativa. Il vincolo sulla cancellazione dei dati di prova è altrettanto ragionevole, ma il sistema lo comunica solo dopo un tentativo fallito, e la partecipante lo ha scoperto sbagliando. Nel primo caso il sistema spiega la regola prima dell'errore, nel secondo dopo. Anche la riorganizzazione in schede ordinate secondo il percorso di configurazione aiuta, perché mostra la struttura dello studio prima che l'utente debba ricostruirla da solo.

Sul lato del ricercatore la risposta è quindi positiva, con un'indicazione precisa su come la configurazione va presentata. La seconda metà della domanda riguarda chi annota.

6.2 Il lato dell'annotatore

La sovrapposizione degli span crea problemi di interazione che il formato dei dati da solo non risolve, come sostiene il gap. L'episodio del pulsante *Clear* (§5.1.2) ne è un esempio. Un pulsante che può voler dire cancellare l'ultimo span oppure tutti è ambiguo in ogni caso, ma con span separati l'utente vedrebbe subito quale è sparito. Con più span sovrapposti sulla stessa porzione di testo l'ultimo creato non si distingue dagli altri, e l'effetto del clic diventa imprevedibile. La sovrapposizione rende quindi rischiosa un'ambiguità che altrimenti resterebbe innocua, e la soluzione è un'etichetta che dichiara cosa succede.

Saper rappresentare span sovrapposti, come fanno quasi tutti gli strumenti del capitolo 2, quindi non basta a renderli gestibili per chi annota. Le scelte descritte in §4.1, dall'aggancio ai confini di parola alle fasce impilate fino alle etichette che compaiono al passaggio del mouse, rispondono a questo problema, cioè rendere leggibile e controllabile un testo su cui convivono più interpretazioni.

Quanto queste scelte riducano errori e disaccordo rispetto a uno strumento come Potato è una misura che la sessione non fornisce, e il capitolo 7 descrive lo studio che servirebbe a ottenerla.

Le due sezioni hanno risposto alla domanda una metà alla volta. La sezione seguente le legge insieme rispetto al gap.

6.3 Cosa significa per il gap

Il gap individuato nel capitolo 2 riguarda il modo in cui gli strumenti esistenti trattano la sovrapposizione. Prodigy, doccano, INCEpTION e Label Studio la rappresentano come estensione del formato, la rendono un'opzione da abilitare o la affidano a utenti esperti, mentre Potato, l'unico tra questi pensato per il crowdsourcing, la gestisce impilando le fasce ma accumula le etichette sopra il testo nel punto di intersezione (§2.2). In tutti i casi la domanda implicita è se lo strumento sappia rappresentare la sovrapposizione. Questa tesi propone di affiancarle una seconda domanda, cioè se chi la incontra per la prima volta riesca a gestirla.

I risultati indicano che questa seconda domanda vale per entrambi i ruoli. L'annotatore occasionale è il soggetto del gap, ma anche il ricercatore che apre il sistema per la prima volta si trova nella stessa condizione. Il dataset nascosto, il vincolo scoperto sbagliando e il pulsante ambiguo sono tutti ostacoli incontrati al primo contatto, mentre il banner di clonazione e le schede riordinate funzionano perché spiegano le regole del sistema prima dell'errore. Per uno strumento rivolto a persone senza addestramento specifico, quindi, il modo in cui le funzioni vengono presentate va progettato con la stessa cura delle funzioni.

È anche la condizione perché le implicazioni descritte nell'introduzione (§1.6) si realizzino. Un sistema integrato rende gli studi di unitizing accessibili a gruppi senza un'infrastruttura propria solo se chi lo usa per la prima volta riesce a orientarsi.

Allo stesso modo, riduce il disaccordo prodotto dall'interfaccia solo se l'annotatore occasionale capisce cosa sta facendo quando gli span si sovrappongono.

6.4 In sintesi

Sul lato del ricercatore i risultati sostengono la proposta di integrare il ciclo dello studio, a patto di presentare la configurazione in modo che le sue regole siano visibili prima dell'errore. Sul lato dell'annotatore confermano che la sovrapposizione degli span è un problema di interazione oltre che di rappresentazione. Le due metà hanno in comune il problema del primo contatto, che riguarda allo stesso modo chi annota e chi configura. Il capitolo seguente esamina le scelte di valutazione che delimitano queste conclusioni.

Capitolo 7

Limitazioni e sviluppi futuri

Le conclusioni del capitolo precedente dipendono da tre scelte fatte nel valutare il sistema. La prima è aver valutato il sistema con una sola esperta in una sessione guidata (§7.1). La seconda è aver affidato la valutazione a una ricercatrice invece che a chi annota (§7.2). La terza è aver costruito il sistema attorno a un unico caso di studio (§7.3). Per ciascuna il capitolo spiega perché era una scelta ragionevole e cosa lascia fuori. L'ultima sezione (§7.4) indica da dove ripartire.

7.1 Una sola valutatrice, in una sessione guidata

Il sistema è stato valutato da una sola persona, Veronika Batzdorfer, in una sessione in cui il candidato condivideva lo schermo e si muoveva nell'interfaccia. Per un primo test era la scelta più sensata. Il sistema non era mai stato usato da un utente reale, e Veronika aveva già condotto PsyCoMark, quindi sapeva bene cosa serve a un ricercatore che prepara uno studio di questo tipo. I vantaggi e i limiti della forma guidata sono già descritti in §5.1.1.

Sei dei sette task riguardavano però la configurazione e il ciclo di vita del progetto, quindi quasi tutte le osservazioni raccolte riguardano quella parte del sistema. Inoltre, con il candidato alla guida, è più difficile vedere i punti in cui un utente si blocca da solo. Il vincolo sulla cancellazione dei dati di prova è emerso comunque, ma altri ostacoli potrebbero essere rimasti nascosti.

Per la tesi questo significa che le osservazioni sul lato del ricercatore, compreso il problema del primo contatto discusso nel capitolo 6, vengono da una sola persona esperta. Non sappiamo ancora se un ricercatore con meno esperienza incontrerebbe gli stessi ostacoli o altri diversi.

7.2 Chi ha valutato non è chi annota

Il gap da cui parte la tesi riguarda chi annota per la prima volta, cioè un lavoratore reclutato su una piattaforma di crowdsourcing senza addestramento specifico (§1.2). Il sistema invece è stato valutato da una ricercatrice esperta, che lo ha guardato soprattutto dal lato della configurazione. Il lato dell'annotatore è entrato nella sessione solo durante l'annotazione di prova, da cui è emerso l'episodio del pulsante *Clear*.

Per questo la tesi non dispone di misure su errori di confine, tempi di annotazione o accordo tra annotatori. Le scelte dell'interfaccia descritte in §4.1, come l'aggancio ai confini di parola e le fasce impilate, sono sostenute dal ragionamento di progettazione e dal confronto con Potato, ma non da dati raccolti su annotatori reali.

Verificare prima il lato del ricercatore ha però una ragione. Uno studio con annotatori pagati funziona solo se ingresso da Prolific, onboarding, distribuzione dei documenti e controllo qualità sono già affidabili. Come visto in §5.1, un errore di configurazione si scopre spesso solo a raccolta conclusa e si traduce in dati da scartare e compensi spesi inutilmente. Il sistema descritto in questa tesi è l'infrastruttura che uno studio sugli annotatori richiede, e averla verificata riduce questo rischio.

7.3 Un solo caso di studio

Il sistema è nato da PsyCoMark ed è stato costruito e provato su quel compito, con cinque etichette di span, una domanda di classificazione sul documento, commenti Reddit come testi e Prolific come piattaforma di reclutamento. Partire da un caso concreto ha permesso di confrontarsi con chi quel problema lo aveva già affrontato.

Il prezzo è che non sappiamo ancora quanto il sistema si adatti ad altri task. Lo schema dichiarativo (§3.3) permette di cambiare etichette, colori e domande senza modificare il codice, e l'interfaccia si costruisce a partire dallo schema. Altri task citati nell'introduzione, come l'estrazione di entità annidate o l'argument mining, potrebbero però richiedere componenti che oggi il sistema non offre, per esempio le relazioni tra span. Allo stesso modo l'ingresso degli annotatori è pensato per Prolific, e altre piattaforme di reclutamento richiederebbero un adattamento.

La tesi mostra quindi che il sistema funziona per il caso da cui è nato. La sua generalità resta da verificare usandolo su un task diverso.

Ciascuno di questi tre limiti indica anche da dove ripartire.

7.4 Sviluppi futuri

Il passo più importante è uno studio con annotatori reclutati su Prolific, che usino questo sistema e uno strumento esistente come Potato sugli stessi documenti. Lo studio misurerebbe gli errori di confine rispetto alle gold unit, il tempo per documento e l'accordo tra annotatori, calcolato con misure adatte all'unitizing (Krippendorff et al. 2016). Il sistema ha già quasi tutto ciò che serve. L'ingresso da Prolific e l'onboarding preparano gli annotatori, la strategia a piena sovrapposizione assegna a tutti gli stessi documenti e il tempo di ogni annotazione viene già registrato. Uno studio di questo tipo direbbe se l'interfaccia riduce il disaccordo dovuto allo strumento, che è la domanda da cui la tesi è partita.

Per il primo limite serve un secondo cognitive walkthrough, questa volta senza guida e con più ricercatori, inclusi alcuni che non hanno mai condotto uno studio in crowdsourcing. Servirebbe a capire quali difficoltà sono comuni a tutti e a verificare se le modifiche introdotte dopo la prima sessione, come la divisione in schede e il pulsante *Clear all*, funzionano.

Per il terzo limite basta usare il sistema su un task diverso da PsyCoMark. Ogni nuovo task mostrerebbe quali componenti mancano allo schema, e l'interfaccia è

costruita in modo da poterli aggiungere senza modificare quelli esistenti. Le relazioni tra span sono il primo candidato.

La Discussione suggerisce poi un intervento concreto sul lato del ricercatore, cioè mostrare i vincoli del ciclo di vita del progetto prima che l'utente li violi. Il caso più evidente è la cancellazione dei dati di prova, che oggi si scopre solo dopo un tentativo fallito.

Restano infine due estensioni più piccole già emerse nel lavoro. La prima è poter modificare i confini di uno span esistente invece di cancellarlo e ricrearlo. La seconda è trasformare il tempo già registrato per ogni annotazione in un tempo minimo per documento, come chiesto durante la sessione.

Il sistema è rilasciato come open source anche per questo motivo. Chi vuole condurre uno di questi studi può partire da un'infrastruttura già funzionante invece di costruirne una propria. Il capitolo seguente chiude la tesi riprendendone i messaggi principali.

Capitolo 8

Conclusioni

Questa tesi è partita da un compito concreto, quello di PsyCoMark, in cui annotatori reclutati online dovevano individuare nei commenti Reddit le porzioni di testo che esprimono gli elementi di una narrativa complottista. L'accordo basso misurato sugli span lasciava aperto quanto del disaccordo dipendesse dal testo e dalle letture diverse che ammette, e quanto invece dagli strumenti con cui l'annotazione era stata raccolta.

Per separare queste due cause servono prima di tutto condizioni di raccolta controllate, e il lavoro si è concentrato su queste. Il sistema sviluppato dà al ricercatore un solo posto in cui preparare, condurre e sorvegliare uno studio di unitizing in crowdsourcing, e dà a chi annota un'interfaccia in cui definire span sovrapposti direttamente sul testo. Le due parti condividono la stessa configurazione, che stabilisce cosa viene annotato, da chi e con quali controlli.

La valutazione con una ricercatrice tra gli organizzatori di PsyCoMark ha dato indicazioni chiare sulla prima parte. L'integrazione del ciclo risponde a un bisogno che chi ha già condotto uno studio simile riconosce, e i problemi emersi riguardano soprattutto il modo in cui la configurazione viene presentata. Sulla seconda parte le indicazioni sono più deboli. La sessione ha confermato che la sovrapposizione degli span crea problemi di interazione propri, ma non ha misurato se l'interfaccia proposta li risolva meglio delle alternative.

Per rispondere alla domanda iniziale serve quindi uno studio con annotatori reali, che confronti errori di confine, tempi e accordo tra strumenti diversi e separi il disaccordo prodotto dall'interfaccia da quello che riflette letture legittimamente diverse dello stesso testo. Il sistema descritto in questa tesi è stato costruito anche per rendere possibile quello studio.

Il sistema supporta in modo specifico l'estrazione di span sovrapposti, ma tutta la parte che gestisce lo studio, dall'ingresso dei partecipanti all'onboarding, alla distribuzione dei documenti e al controllo qualità, non dipende da questo task. Può quindi essere riutilizzata ed estesa per altri studi di annotazione in crowdsourcing. Per questo il sistema è rilasciato come open source, così che possa servire ad altri gruppi di ricerca senza che ciascuno debba ricostruirsi da zero la propria infrastruttura.

Bibliografia

- Cabitza, Federico, Andrea Campagner e Valerio Basile (2023). «Toward a Perspectivist Turn in Ground Truthing for Predictive Computing». In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 37. 6, pp. 6860–6868. DOI: 10.1609/aaai.v37i6.25840.
- Finkel, Jenny Rose e Christopher D. Manning (2009). «Nested Named Entity Recognition». In: *Proceedings of the 2009 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, pp. 141–150. URL: <https://aclanthology.org/D09-1015/>.
- Hovy, Dirk et al. (2013). «Learning Whom to Trust with MACE». In: *Proceedings of the 2013 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Association for Computational Linguistics, pp. 1120–1130. URL: <https://aclanthology.org/N13-1132/>.
- Klie, Jan-Christoph et al. (2018). «The INCEpTION Platform: Machine-Assisted and Knowledge-Oriented Interactive Annotation». In: *Proceedings of the 27th International Conference on Computational Linguistics: System Demonstrations*. Association for Computational Linguistics, pp. 5–9. URL: <https://aclanthology.org/C18-2002/>.
- Krippendorff, Klaus et al. (2016). «On the Reliability of Unitizing Textual Continua: Further Developments». In: *Quality & Quantity* 50.6, pp. 2347–2364. DOI: 10.1007/s11135-015-0266-1.
- Montani, Ines e Matthew Honnibal (2018). *Prodigy: A New Annotation Tool for Radically Efficient Machine Teaching*. Explosion. URL: <https://prodi.gy>.
- Nakayama, Hiroki et al. (2018). *doccano: Text Annotation Tool for Human*. Software. URL: <https://github.com/doccano/doccano>.
- Neves, Mariana e Jurica Ševa (2021). «An Extensive Review of Tools for Manual Annotation of Documents». In: *Briefings in Bioinformatics* 22.1, pp. 146–163. DOI: 10.1093/bib/bbz130.
- Pei, Jiaxin et al. (2022). «POTATO: The Portable Text Annotation Tool». In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. Association for Computational Linguistics, pp. 327–337. URL: <https://aclanthology.org/2022.emnlp-demos.33/>.
- Samory, Mattia, Felix Soldner e Veronika Batzdorfer (2026). «SemEval-2026 Task 10: PsyCoMark – Psycholinguistic Conspiracy Marker Extraction and Detection». In: *Proceedings of the 20th International Workshop on Semantic Evaluation (SemEval-2026)*. Association for Computational Linguistics. URL: <https://aclanthology.org/2026.semeval-1.444/>.

- Stab, Christian e Iryna Gurevych (2017). «Parsing Argumentation Structures in Persuasive Essays». In: *Computational Linguistics* 43.3, pp. 619–659. DOI: 10.1162/COLI_a_00295.
- Tkachenko, Maxim et al. (2020). *Label Studio: Data Labeling Software*. Open source software. URL: <https://github.com/HumanSignal/label-studio>.
- Wharton, Cathleen et al. (1994). «The Cognitive Walkthrough Method: A Practitioner's Guide». In: *Usability Inspection Methods*. A cura di Jakob Nielsen e Robert L. Mack. New York: John Wiley & Sons, pp. 105–140.
- Zhang, Wenxuan et al. (2023). «A Survey on Aspect-Based Sentiment Analysis: Tasks, Methods, and Challenges». In: *IEEE Transactions on Knowledge and Data Engineering* 35.11, pp. 11019–11038. DOI: 10.1109/TKDE.2022.3230975.

Ringraziamenti

A mamma e papà, che mi hanno dato la possibilità di intraprendere questo percorso e di arrivare fino a qui. Vi ringrazio soprattutto perché gli ultimi anni non sono stati facili, e voi mi avete lasciato sbagliare, capire e migliorare, sostenendomi sempre. Forse non ve lo dico abbastanza, quindi ve lo scrivo qui. Grazie per esserci sempre.

A Silvia e Valeria, le gemelline,

A Elisa,

A Francesca, la mia compagna di vita da ormai più di cinque anni. Questo traguardo è quasi più tuo che mio, perché mi hai visto in tutte le versioni possibili. Il Matteo scansafatiche, il Matteo studioso, il Matteo impegnato e il Matteo lavoratore. Grazie per aver voluto bene a ognuno di loro.

A David e Antonio,

A Tommaso e Laura,

Ai miei amici di sempre,