



SAPIENZA
UNIVERSITÀ DI ROMA

Progettazione e Sviluppo di una Piattaforma Full-Stack per l'Annotazione di Narrative Complottiste tramite Crowdsourcing

Facoltà di Ingegneria dell'Informazione, Informatica e Statistica
Laurea Triennale in Informatica

Matteo Pasquale Geusa

Matricola 2058638

Relatore

Prof. Matteo Cinelli

Correlatore

Prof. Mattia Samory

Anno Accademico 2025/2026

Tesi non ancora discussa

**Progettazione e Sviluppo di una Piattaforma FullStack per l'Annotazione di
Narrative Complotte tramite Crowdsourcing**

Tesi di Laurea Triennale. Sapienza Università di Roma

© 2026 Matteo Pasquale Geusa. Tutti i diritti riservati

Questa tesi è stata composta con L^AT_EX e la classe Sapthesis.

Email dell'autore: matteogeusa03@gmail.com

Dedicato a

Sommario

Riassunto

Indice

1	Introduzione	1
2	Background e lavori correlati	3
2.1	Il caso di studio, PsyCoMark	3
2.2	Gli strumenti di annotazione esistenti	3
2.3	Controllo della qualità nel crowdsourcing	4
2.4	Che cosa manca	4
3	Dati, Materiali e Definizioni	5
3.1	Il progetto come unità di configurazione	5
3.2	Formalizzazione del task di annotazione	6
3.3	Lo schema di annotazione	7
3.4	Formato del dataset	8
3.5	Le gold unit	9
3.6	Annotatore e partecipazione al progetto	9
4	Metodi	11
4.1	L'interazione di annotazione	11
4.2	L'ingresso nel progetto	13
4.3	Amministrazione del task live	17
4.4	Configurazione del task	20
4.5	Architettura del sistema	22
5	Risultati	25
5.1	La valutazione con un'esperta di dominio	25
5.1.1	Perché un cognitive walkthrough, e con chi	25
5.1.2	Cosa è emerso	26
5.1.3	Cosa ha convinto	28
5.1.4	Dalle osservazioni agli interventi	29
5.1.5	Due prove, la stessa debolezza	29
5.1.6	In sintesi	30
6	Discussione	31
6.1	Le aspettative di partenza	31
6.2	L'integrazione del ciclo regge	31
6.3	Il controllo qualità	32
6.4	Una configurazione unica sposta il rischio	34

6.5	Cosa i risultati dicono sul gap	34
6.6	Una tensione con il prospettivismo	35
6.7	In sintesi	35
7	Limitazioni e Sviluppi Futuri	37
8	Conclusioni	39

Capitolo 1

Introduzione

Capitolo 2

Background e lavori correlati

Questo capitolo serve a chiarire il problema affrontato dalla tesi prima ancora di parlare della soluzione. Si parte dal caso di studio che l'ha originato, cioè l'annotazione di marcatori psicolinguistici in commenti complottisti, si passa alla famiglia di task che condividono la stessa difficoltà, cioè quelli in cui le unità annotate si sovrappongono, si vede come si misura l'accordo quando le unità non sono date in anticipo, e si chiude con gli strumenti di annotazione esistenti.

2.1 Il caso di studio, PsyCoMark

Il lavoro nasce da un compito concreto. PsyCoMark, la Task 10 di SemEval-2026 (Samory, Soldner e Batzdorfer 2026), chiede di estrarre da commenti Reddit cinque marcatori psicolinguistici radicati nella psicologia evoluzionistica e poi di classificare il contenuto come complottista o meno. I cinque marcatori sono Actor, cioè le entità cui viene attribuito il complotto, Action, le attività ingannevoli attribuite ai cospiratori, Effect, le conseguenze o il danno prodotti, Victim, chi ne è colpito, ed Evidence, le prove addotte a sostegno della credenza. Il corpus raccoglie 5.354 commenti da 226 subreddit, scelti in modo da mescolare comunità dichiaratamente complottiste e comunità ordinarie, così che i marcatori non coincidano con l'argomento della discussione.

Due aspetti di questo compito contano per il resto della tesi. Il primo è che gli span dei marcatori possono sovrapporsi, ed è il paper stesso a dirlo, perché un documento può contenere più span per ciascun marcatore e questi possono sovrapporsi tra loro. Il secondo è che l'annotazione è stata condotta in crowdsourcing, con 138 lavoratori reclutati su Prolific e un percorso fatto di consenso informato, questionario preliminare, istruzioni con codebook, task di addestramento e infine dieci documenti da annotare.

2.2 Gli strumenti di annotazione esistenti

Gli strumenti generalisti per l'annotazione testuale non mancano, e una rassegna sistematica ne ha censiti molti mettendo proprio la possibilità di sovrapporre span tra i criteri di confronto (Neves e Ševa 2021). Vale quindi la pena guardare come i più diffusi trattano la sovrapposizione e per quale tipo di utente sono progettati.

Potato è open source ed è esplicitamente pensato per il crowdsourcing, perché prevede l'ingresso degli annotatori tramite Prolific, e nelle versioni recenti gestisce gli span sovrapposti impilando le fasce e riducendo a pallini le etichette che si scontrano (Pei et al. 2022). Prodigy è commerciale e supporta in modo nativo span sovrapposti e annidati, ma si rivolge a sviluppatori e a chi costruisce dataset in prima persona, non a lavoratori reclutati su una piattaforma (Montani e Honnibal 2018). doccano è open source e permette la sovrapposizione solo se il ricercatore attiva un'apposita opzione, disattivata per impostazione predefinita (Nakayama et al. 2018). INCEpTION, rivolto ad annotatori esperti in contesti accademici, rende la sovrapposizione una proprietà configurabile per ciascun livello di annotazione, anch'essa disattivata di default (Klie et al. 2018). Label Studio dichiara il supporto agli span sovrapposti nei propri modelli di progetto, ma distribuisce anche un componente aggiuntivo il cui scopo è segnalare un errore e bloccare l'invio quando due span si sovrappongono (Tkachenko et al. 2020).

Ne emerge un quadro coerente. La sovrapposizione è rappresentabile quasi ovunque, però resta trattata come un'eccezione da abilitare, oppure come una funzione rivolta a chi annota per mestiere. Quello che nessuno di questi strumenti documenta è il lato dell'annotatore occasionale, cioè quante etichette restino leggibili quando si accumulano sulla stessa porzione di testo, cosa accada al testo sottostante e come si selezioni o si rimuova uno span sepolto sotto altri. Ed è esattamente la condizione di chi annota in crowdsourcing, senza addestramento specifico, che è il contesto in cui PsyCoMark ha raccolto i suoi dati.

2.3 Controllo della qualità nel crowdsourcing

Resta un ultimo elemento di contesto, perché un'annotazione raccolta da persone non addestrate richiede che la sua affidabilità venga stimata. Due approcci ricorrono in letteratura. Il primo consiste nell'inserire nel flusso di lavoro documenti con soluzione nota, contro cui confrontare le risposte. Il secondo stima congiuntamente l'etichetta corretta e la competenza di ciascun annotatore a partire dalle sole annotazioni raccolte, senza soluzioni note, ed è l'approccio di MACE (Hovy et al. 2013). I due si completano, perché il primo misura pochi casi in modo diretto mentre il secondo sfrutta l'intero volume raccolto, ed entrambi sono ripresi nel capitolo Metodi (§4).

2.4 Che cosa manca

Mettendo insieme i tre quadri, il posto lasciato vuoto si vede. Esistono task, e PsyCoMark è uno di questi, in cui le unità da annotare si sovrappongono e devono essere raccolte da annotatori non specializzati. Esistono misure di accordo adatte a questo caso. Esistono strumenti di annotazione che sanno rappresentare la sovrapposizione, ma la trattano come un'opzione da abilitare o la offrono a un pubblico di esperti, e nessuno documenta come renderla governabile da chi annota per la prima volta. Il sistema descritto nei capitoli seguenti si colloca in questo spazio.

Capitolo 3

Dati, Materiali e Definizioni

Il capitolo procede dal progetto ovvero l'unità che racchiude ogni aspetto di uno studio di annotazione, verso le sue parti costitutive, cosa produce una singola istanza di annotazione, cosa ne vincola la forma, quali dati la alimentano, come si misura la qualità delle risposte raccolte, e chi le produce.

3.1 Il progetto come unità di configurazione

Ogni studio di annotazione nasce da un progetto, l'oggetto che raccoglie in un unico posto le scelte che lo definiscono ovvero chi lo cura, cosa va annotato, come deve essere annotato, chi annota, come si verifica la qualità delle risposte.

Un progetto riunisce in un'unica configurazione il dataset da annotare (§3.4), lo schema di annotazione che vincola la forma di ogni istanza (§3.3), il flusso di onboarding dei partecipanti (§3.6), il controllo qualità tramite gold unit (§3.5), e le modalità di distribuzione dei documenti sul bacino di annotatori.




Figura 3.1. Transizione degli stati di un progetto

Un progetto attraversa quattro stati nel corso della sua vita: bozza, attivo, in pausa, completato. Accetta nuove istanze di annotazione solo nello stato attivo. In bozza è modificabile liberamente in ogni suo aspetto. Una volta attivato (passaggio che richiede almeno un documento nel dataset), la pubblicazione blocca la configurazione, schema compreso, poiché anche lo schema ne è un campo, e la rende modificabile solo clonando il progetto. Il blocco previene situazioni in cui se lo

schema o i criteri di distribuzione cambiassero a raccolta già avviata, le annotazioni raccolte prima e dopo il cambiamento non sarebbero più confrontabili tra loro.

Chi cura un progetto assume un ruolo distinto da chi vi partecipa. Il ricercatore è chi crea il progetto; può aggiungere altri collaboratori, per condividere la gestione dello studio. L'annotatore, il ruolo trattato dal resto del capitolo, non configura il progetto ma vi partecipa.

Le sezioni seguenti riprendono uno per uno gli elementi che il progetto raccoglie, prima l'unità di lavoro che l'annotatore produce, poi cosa ne vincola la forma, quali dati la alimentano, come si verifica la sua qualità, infine chi la produce.

3.2 Formalizzazione del task di annotazione

Classificare un testo assegna un'unica etichetta all'intero documento, senza indicare quale porzione la giustifica. Il task trattato in questo capitolo richiede di individuare quali porzioni di testo, dette *span*, sostengono ciascuna etichetta, e permettere che porzioni diverse si sovrappongano, quando più interpretazioni convivono sullo stesso testo. Questo compito, noto in letteratura come *unitizing*, produce per ogni documento un'istanza di annotazione: l'unità di lavoro assegnata a un singolo annotatore su un singolo documento. L'istanza di annotazione prodotta da un annotatore su questo testo ha il formato seguente:

```
{
  "pid": "TESTER",
  "document": "8e9cf589-86d5-4874-aa8a-8b7f9b9998d8",
  "result": {
    "span_highlight": [
      {
        "start": 30,
        "end": 44,
        "label": "Actor",
        "text": "the government",
        "id": "span-1788854071889-118"
      },
      {
        "start": 45,
        "end": 70,
        "label": "Action",
        "text": "to control public opinion",
        "id": "span-1788854071889-119"
      },
      {
        "start": 27,
        "end": 70,
        "label": "Threat",
        "text": "by the government to control public opinion",
        "id": "span-1788854071889-120"
      }
    ],
    "classification": "Yes"
  }
}
```

```
}

```

Un'istanza di annotazione contiene un insieme di span, ciascuno con un indice di inizio, un indice di fine e un'etichetta assegnata, come mostra il campo `span_highlight`, e, quando lo schema lo prevede, una o più etichette di classificazione a livello di documento, come mostra il campo `classification`.

Due span sono in overlap quando condividono almeno un carattere: dati due span $(start_1, end_1)$ e $(start_2, end_2)$, vale $start_1 < end_2$ e $start_2 < end_1$. Il task ammette questa sovrapposizione perché la stessa porzione di testo può sostenere più interpretazioni distinte, indipendentemente dall'etichetta assegnata.

Span, overlap e istanza di annotazione sono i tre termini su cui si costruisce il resto del capitolo: non cambiano significato altrove nella tesi.

3.3 Lo schema di annotazione

Lo schema di annotazione, uno dei campi della configurazione del progetto, vincola cosa deve produrre ogni istanza di annotazione: quali componenti sono previsti, e per ciascuno quali etichette o opzioni sono disponibili. È una struttura dichiarativa definita direttamente dal ricercatore.

Il sistema supporta due tipi di componenti. Il componente `span_highlight` definisce un insieme di etichette per l'annotazione di span: di ciascuna sono obbligatori un nome e un colore, più un suggerimento testuale mostrato all'annotatore. Il componente `classification` definisce una domanda a scelta singola o multipla applicata all'intero documento. Un progetto attiva uno dei due componenti, o entrambi insieme.

Lo schema seguente, definisce lo schema ibrido per l'annotazione di narrative complottiste, a differenza degli esempi mostrati finora, che compilano un'istanza su un documento specifico, lo schema seguente non descrive un caso concreto: definisce le regole che ogni istanza del progetto deve rispettare, qualunque sia il documento. Per questo il formato cambia, da JSON con span e indici a una lista dichiarativa di etichette.

```
components:
- type: span_highlight
  labels:
  - name: Actor
    color: "#FF5733"
    hover_hint: "Who is allegedly responsible for a malicious action or agenda?"
  - name: Action
    color: "#33FF57"
    hover_hint: "What is the actor doing or planning to do to cause negative outcomes?"
  - name: Victim
    color: "#3357FF"
    hover_hint: "Who is negatively affected by the actor's agenda?"
  - name: Threat
    color: "#FF33F6"
```

```

    hover_hint: "What is the actor doing or planning to do to cause
        negative outcomes?"
  - name: Evidence
    color: "#FFA500"
    hover_hint: "Which arguments or expressions does the writer of the
        text use to support his claims?"

- type: classification
  question: "Is this text related to a conspiracy theory?"
  multi_select: false
  options:
    - label: Conspiracy
      value: "Yes"
    - label: Not Conspiracy
      value: "No"
    - label: Ambiguous
      value: "Can't tell"

```

Ogni componente ha una specifica formale di campi obbligatori e opzionali. Un campo mancante o non riconosciuto rende lo schema invalido: il sistema lo rifiuta al momento del caricamento.

Lo schema stabilisce la forma di ogni istanza di annotazione; la sezione seguente stabilisce cosa viene distribuito agli annotatori perché la producano.

3.4 Formato del dataset

Il dataset di un progetto non è diviso in split di addestramento, validazione e test ma è un unico file JSONL, dove ogni riga rappresenta un documento in formato JSON.

Le chiavi che identificano il testo e l'identificativo del documento sono configurabili per progetto, dato che non tutti i dataset usano gli stessi nomi di campo. Ogni chiave aggiuntiva presente nella riga viene preservata come metadato associato al documento, ad esempio il subreddit o l'id del thread di provenienza:

```

{"id": "t1_abc123",
 "subreddit": "conspiracy",
 "text": "The moon landing was faked by the government to control public
  opinion."}

```

Il materiale annotato proviene da PsyCoMark, il dataset ufficiale della Task 10 di SemEval-2026, dedicata all'estrazione di marcatori psicolinguistici e alla rilevazione di narrative complottiste (Samory, Soldner e Batzdorfer, 2026). Il corpus è composto da commenti Reddit raccolti su comunità eterogenee, dalla politica alle serie televisive. In questa tesi il dataset si impiega in forma redatta, per tutelare la privacy degli autori dei commenti originali.

Tra le righe del dataset, alcune hanno una soluzione nota: sono le gold unit, trattate nella sezione seguente.

3.5 Le gold unit

Una gold unit è una riga del dataset con soluzione nota, usata per misurare quanto le risposte di un annotatore si avvicinano a quella soluzione.

La soluzione, nel campo `gold_solution`, condivide lo stesso schema di annotazione del progetto: può essere un insieme di span, una classificazione, o entrambi insieme. Può anche essere parziale, per limitare la verifica a una sola parte della risposta:

```
{
  "text": "The moon landing was faked by the government to control public opinion.",
  "gold_solution": {
    "classification": "Yes",
    "span_highlight": [
      {
        "start": 30,
        "end": 44,
        "label": "Actor",
        "text": "the government"
      },
      {
        "start": 45,
        "end": 70,
        "label": "Action",
        "text": "to control public opinion"
      },
      {
        "start": 27,
        "end": 70,
        "label": "Threat",
        "text": "by the government to control public opinion"
      }
    ]
  }
}
```

Questo stesso documento, già usato in §3.2 e in §3.4, è la gold unit di riferimento nel resto della tesi: ogni esempio del capitolo Metodi si appoggia su di essa.

3.6 Annotatore e partecipazione al progetto

Un annotatore è identificato da un identificativo esterno al sistema, in questo caso quello assegnato da Prolific, il servizio di reclutamento usato; il sistema non ne conserva altro, a parte metadati.

Lo stesso annotatore può partecipare a più progetti contemporaneamente, ciascuno con la propria selezione, il proprio studio, i propri criteri di qualità. Il sistema separa perciò lo stato di un annotatore dall'annotatore stesso: non è una sua proprietà, ma una proprietà della sua partecipazione a un progetto specifico, rappresentata dalla coppia annotatore-progetto.

In questa coppia si registrano tre cose: lo stato di avanzamento (in attesa, attivo, escluso, completato), il superamento delle fasi di onboarding, cioè la sequenza di passaggi preparatori che precede l'annotazione vera e propria (il consenso informato, lo screening, un questionario di eleggibilità e demografia, e il codebook, il materiale

teorico-pratico che spiega come interpretare il task), e le metriche di affidabilità calcolate sulle gold unit.

Di conseguenza, lo stesso annotatore può risultare attivo su un progetto ed escluso su un altro infatti l'affidabilità misurata non è una proprietà dell'annotatore in generale, ma è specifica al singolo studio.

Progetto, istanza di annotazione, schema, dataset, gold unit e annotatore sono i termini su cui si costruisce il capitolo Metodi: lì si descrive come il sistema realizza concretamente ciò che qui è stato definito, non cosa questi termini significano.

Capitolo 4

Metodi

Il capitolo precedente (§3) definisce gli elementi costitutivi dell'applicazione, quali progetto, istanza di annotazione, schema, dataset, gold unit, annotatore. Questo capitolo descrive come il sistema li realizza, seguendo separatamente il percorso dell'annotatore e quello del ricercatore che amministra il task. Per ciascuno si parte dal momento centrale e si risale poi a ciò che lo prepara. Per l'annotatore si parte dall'interazione di annotazione, con l'overlap come contributo centrale (§4.1), e si risale all'ingresso nel progetto (§4.2). Per il ricercatore si parte dall'amministrazione del task mentre raccoglie dati (§4.3) e si risale alla sua configurazione (§4.4). L'ultima sezione descrive cosa c'è sotto a rendere tutto questo eseguibile, l'architettura del sistema (§4.5). Le schermate sono presentate nel punto in cui l'utente le incontra.

4.1 L'interazione di annotazione

Tutto il sistema esiste per rendere affidabile un momento preciso, quello in cui un annotatore legge un testo e lo annota. Il percorso dell'annotatore parte quindi da qui.

Ricevuto un documento (§4.4), l'annotatore lo affronta attraverso l'interfaccia di annotazione. I documenti arrivano uno alla volta. Quando l'annotatore invia la risposta, il sistema gli propone il successivo, finché la strategia di distribuzione (§4.4) non ha più documenti da assegnargli. A quel punto lo rimanda alla piattaforma di reclutamento con il codice di completamento. Nello stesso flusso arrivano anche le gold unit (§3.5), che l'interfaccia segnala con un banner in cima al documento.

Il capitolo precedente ammette l'overlap tra span come proprietà del task (§3.2). Il sistema lo traduce in un'interazione diretta sul testo, non in un vincolo di formato dati. Questa interfaccia, tramite cui l'annotatore definisce gli span, è il contributo centrale del sistema.




Figura 4.1. L'interfaccia di annotazione aggancia automaticamente la selezione ai confini di parola.

La selezione avviene sul testo (Figura 4.1), con un aggancio automatico alla parola intera. Se la selezione dell'utente termina a metà parola o include spazi in eccesso, il sistema sposta i margini forzandoli ai confini della parola intera più vicina. Questo elimina un errore comune nell'annotazione di span, i confini imprecisi dovuti alla difficoltà di selezionare con il mouse esattamente i caratteri desiderati.

Gli strumenti di annotazione attuali offrono un supporto nullo o limitato per l'unitizing con overlap. Anche uno strumento generalista come Potato (Pei et al. 2022), che permette di selezionare span sovrapposti trascinando direttamente sul testo, sovrappone però le etichette dei singoli span nel punto di intersezione, coprendo sia le etichette stesse sia il testo sottostante (Figura 4.2).




Figura 4.2. In Potato le etichette degli span sovrapposti si accumulano nel punto di intersezione e coprono il testo.

L'interfaccia qui descritta rende l'overlap un'operazione diretta. Selezionare una seconda volta una porzione di testo già annotata, con un'etichetta diversa, aggiunge un nuovo span senza rimuovere il precedente. Gli span sovrapposti vengono resi visibili con una fascia colorata per span, impilata sotto il testo in base al livello di sovrapposizione (Figura 4.3). L'annotatore vede a colpo d'occhio quante etichette coprono ciascuna porzione di testo, invece di doverlo ricostruire da una lista di coordinate.




Figura 4.3. Gli span sovrapposti sono resi visibili da una fascia colorata impilata per ciascuno.

Le etichette non sono sempre visibili. Compaiono solo al passaggio del mouse, e mostrano tutti gli span che coprono il punto sotto il cursore. Il testo resta così leggibile anche con molte sovrapposizioni, al contrario di quanto avviene in Potato, dove le etichette si accumulano sopra il testo nel punto di intersezione. Nella Figura 4.3 il cursore si trova sullo span che inizia con “NASA”, ed è per questo che solo la sua etichetta è visibile.

Accanto all'etichetta che compare al passaggio del mouse c'è un pulsante che rimuove quello span. I confini di uno span già creato non si modificano, per correggerlo lo si rimuove e lo si ridefinisce con una nuova selezione. L'etichetta da applicare si sceglie dai pulsanti colorati sopra il testo oppure dalla tastiera, perché ogni pulsante riporta il numero che lo richiama, così che un annotatore che lavora su molti documenti non debba spostare la mano sul mouse per cambiare etichetta.

L'interfaccia non è cablata su un task predefinito, ogni componente dello schema (§3.3) corrisponde a un blocco visivo generato dinamicamente, uno per `span_highlight`, uno per `classification`, assemblato in base ai componenti presenti nello schema del progetto. Aggiungere un nuovo tipo di componente al sistema significa aggiungere un nuovo blocco, senza modificare quelli esistenti.

L'interazione qui descritta è ciò che rende l'overlap accessibile all'annotatore, ed è il punto in cui il lavoro di onboarding e distribuzione descritto nelle sezioni seguenti si traduce in una risposta effettiva. La sezione seguente risale ai passaggi che l'annotatore attraversa prima di arrivarci. Come quella risposta viene misurata è descritto in §4.3.

4.2 L'ingresso nel progetto

La sezione precedente ha mostrato l'annotatore al lavoro. Questa descrive come ci arriva. Un annotatore che si iscrive a un progetto non riceve subito documenti da

annotare. Il sistema lo fa prima attraversare una pipeline di onboarding (§3.6), la stessa sequenza di fasi già introdotta nel capitolo precedente, implementata come una macchina a stati.





Figura 4.4. Le fasi della pipeline di onboarding, ciascuna attivabile o disattivabile in configurazione.

Le fasi, riportate in Figura 4.4, sono controllate da un interruttore indipendente nella configurazione del progetto, quindi un progetto minimale può disattivarle tutte e portare l’annotatore direttamente all’annotazione, mentre uno studio più esigente le attiva tutte, incluso l’obbligo di superare un task di pratica prima di procedere. Il motore che gestisce la sequenza è lo stesso in entrambi i casi. Cambia solo la configurazione.

Il contenuto di ogni fase è definito dal ricercatore, non cablato nel sistema. Lo screening è una lista di domande configurabile, caricata come file YAML o JSON, con tipi di risposta diversi (testo, numero, scelta singola o multipla) e domande obbligatorie o facoltative, utili non solo per eleggibilità e demografia di base ma anche per domande personalizzate specifiche dello studio. Codebook e istruzioni sono invece documenti liberi in Markdown, caricati allo stesso modo. La validazione dei file caricati è descritta in §4.4.

L’annotatore entra da un link che contiene il suo identificativo sulla piattaforma di reclutamento e quello del progetto. Se il progetto non è attivo, il sistema rifiuta la sessione. Altrimenti restituisce la fase da cui l’annotatore deve partire. L’avanzamento nella pipeline è registrato nell’iscrizione dell’annotatore (§3.6), non nel client. Un annotatore che torna a metà pipeline riprende da dove aveva lasciato.

La prima fase è il consenso informato. L’annotatore legge il testo preparato dal ricercatore e lo accetta prima di procedere (Figura 4.5).



Informed Consent

Please read the following information carefully before proceeding.

Informed Consent

Welcome to the Study

Thank you for participating in this research study. Please read the following information carefully before proceeding.

Your Task

You will be asked to read and classify a series of short texts. The estimated time to complete all tasks is approximately **15–20 minutes**. The goal of this study is to improve automated systems for analysing online discourse.

Your Data and Privacy

This task is **anonymous**. We do not collect any personally ident...


[Read the full consent form →](#)

☐ I have read and understood the information above.

I Agree

Figura 4.5. Il consenso informato, con il testo definito dal ricercatore, va accettato prima di proseguire.

Segue lo screening, con le domande definite dal ricercatore (Figura 4.6). Se manca una risposta obbligatoria, il server rifiuta l'invio.



About You

Please answer the following questions before starting the task.

1. How old are you? *

2. Gender? *

3. Native language? *

Continue

Figura 4.6. Il questionario di screening, con domande definite dal ricercatore per lo studio specifico.

Il codebook presenta il quadro teorico dello studio, per esempio le definizioni

delle categorie da annotare. L'annotatore lo legge e conferma di averlo fatto prima di passare alle istruzioni (Figura 4.7).




Figura 4.7. Il codebook presenta il quadro teorico dello studio, e l'annotatore conferma di averlo letto.

Le istruzioni spiegano come svolgere il task. Se il ricercatore lo prevede, sono seguite da un task di pratica. L'annotatore annota un testo di esempio con la stessa interfaccia della sezione precedente e riceve subito un riscontro (Figura 4.8). Per ogni span della soluzione vede se l'ha individuato, per la classificazione vede la risposta corretta, e può leggere i suggerimenti preparati dal ricercatore. Il confronto con la soluzione avviene nel browser e usa lo stesso criterio delle gold unit, descritto in §4.3. Se il task di pratica è obbligatorio, l'annotatore deve riprovare finché non risponde correttamente. Altrimenti può proseguire anche dopo un tentativo sbagliato.

The screenshot shows a web interface for a 'Practice Task'. At the top, an orange banner reads 'PRACTICE TASK — Try annotating this example before starting the real task'. Below this, the 'Practice Task' section instructs the user to 'Read the text below and complete the tasks, then submit to see feedback.' To the right, a 'HOW TO ANNOTATE' box lists three steps: 1. Highlight (Click & drag over text), 2. Label (Click a colored button), and 3. Remove (Click an existing highlight). The main area features a 'HIGHLIGHTER' toolbar with five buttons: 'Actor' (red), 'Action' (green), 'Victim' (blue), 'Threat' (purple), and 'Evidence' (yellow). Below the toolbar, a text box contains the sentence: 'The government is putting chips in the water to control us and nobody seems to care about it.' Underneath the text box, a question is posed: 'Is this text related to a conspiracy theory?'. Three radio button options are provided: 'Conspiracy', 'Not Conspiracy', and 'Ambiguous'. At the bottom, there are three buttons: a large blue 'Clear' button, and two smaller grey buttons labeled 'Skip Practice' and 'Submit Practice'.

Figura 4.8. Il riscontro sul task di pratica indica quali span della soluzione sono stati individuati.

Superato l'onboarding, l'annotatore riceve i documenti da annotare. Come il sistema li distribuisce è una scelta del ricercatore, descritta in §4.4. Con l'ingresso nel progetto si chiude il percorso dell'annotatore. Le prossime due sezioni cambiano prospettiva, dal lavoro dell'annotatore a quello del ricercatore che lo rende possibile. La prima descrive come il ricercatore sorveglia uno studio in corso, la seconda come lo configura senza scrivere codice.

4.3 Amministrazione del task live

Il sistema è pensato perché il ricercatore possa configurare e sorvegliare uno studio senza competenze tecniche, un obiettivo che vale sia in fase di configurazione iniziale sia oltre, quando lo studio è già in corso. Questa sezione parte dal secondo caso. Mentre gli annotatori lavorano, il ricercatore ha bisogno di sapere a che punto è la raccolta, se i dati sono di qualità sufficiente e come intervenire se qualcosa non va. Il punto di partenza è la dashboard del progetto (Figura 4.9).




Figura 4.9. La dashboard del progetto. I riquadri numerati indicano lo stato corrente (1), le transizioni disponibili (2), l'avanzamento della raccolta (3) e i conteggi di documenti, gold unit, annotatori e annotazioni (4).

Il primo strumento è lo stato del progetto, definito nel capitolo precedente (§3.1). La dashboard mostra lo stato corrente (1) e le transizioni disponibili (2). Lo stato decide cosa vedono gli annotatori. Solo un progetto attivo accetta sessioni e assegna documenti. Negli altri stati il sistema rifiuta le nuove sessioni, e chi sta annotando riceve un messaggio che avvisa che il progetto non accetta più annotazioni. Quando il progetto è attivo, il ricercatore può aprirlo dall'amministrazione come partecipante di prova e percorrere tutta la pipeline. Finché il progetto resta in modalità playground, cioè attivo ma non ancora pubblicato ufficialmente, tutte le sessioni vengono registrate come prova. Le annotazioni di prova sono conteggiate separatamente da quelle reali e non entrano nella valutazione sulle gold unit. Al momento della pubblicazione ufficiale il sistema cancella tutte le annotazioni e le iscrizioni raccolte fino a quel momento, e la raccolta reale parte da zero.


La dashboard riporta anche l'avanzamento della raccolta (3), calcolato sul numero

di annotazioni ricevute rispetto a quelle richieste dai documenti, insieme al numero di documenti, gold unit, annotatori iscritti e annotazioni raccolte (4).

Le risposte raccolte attraverso l'interfaccia descritta in §4.1 sono ciò che il sistema misura per stimare la qualità del lavoro di un annotatore. Tra i documenti distribuiti (§4.4) figurano anche le gold unit (§3.5). Il sistema le usa per misurare la qualità delle risposte raccolte, con due meccanismi complementari.

Il primo è l'iniezione periodica di gold unit nel flusso di documenti regolari, con una frequenza configurabile per ogni progetto. Quando un annotatore riceve una gold unit, la sua risposta viene confrontata con la soluzione nota componente per componente. La classificazione richiede corrispondenza esatta, mentre gli span richiedono che la soluzione trovi un corrispondente nella risposta dell'annotatore entro una tolleranza di cinque caratteri sui confini.

L'esito di ogni gold unit aggiorna l'accuratezza cumulata dell'annotatore su quel progetto specifico. La decisione di escludere un annotatore è delegata a una strategia di valutazione, isolata dal resto del sistema, che esclude l'annotatore quando l'accuratezza scende sotto una certa soglia configurabile, dopo un numero minimo di gold unit completate. Un annotatore escluso non riceve più documenti e viene avvisato dell'esclusione. La separazione tra meccanismo di iniezione e criterio di esclusione lascia aperta la possibilità di modificare il criterio senza toccare il resto della pipeline di controllo qualità. Il ricercatore vede per ogni iscrizione l'accuratezza raggiunta e lo stato dell'annotatore (Figura 4.10).



Annotator	Type	Project	Status	Gold Tasks Completed	Gold Accuracy	MACE Score	Exclude from distribution	Created at
4c91d5fa7682b0a5f930aa1	Worker	Conspiracy Narrative Detection - Wave 1	ACTIVE	3	67%	0.05	✗	Sept. 20, 2026, 2:28 p.m.
3b80c4e936571af194e82099	Worker	Conspiracy Narrative Detection - Wave 1	EXCLUDED	4	50%	0.33	✗	Sept. 20, 2026, 2:28 p.m.
2a79b3d825460f083d71088	Worker	Conspiracy Narrative Detection - Wave 1	COMPLETED	5	80%	0.43	✗	Sept. 20, 2026, 2:28 p.m.
1f68a2c714359edf72c60077	Worker	Conspiracy Narrative Detection - Wave 1	COMPLETED	5	80%	0.46	✗	Sept. 20, 2026, 2:28 p.m.
0e571fb603248dce6fb5f066	Worker	Conspiracy Narrative Detection - Wave 1	ACTIVE	4	75%	0.28	✗	Sept. 20, 2026, 2:28 p.m.
9d46e0a5f2137cbd50a4e055	Worker	Conspiracy Narrative Detection - Wave 1	COMPLETED	5	80%	0.79	✗	Sept. 20, 2026, 2:28 p.m.
8c35d9f4e1026bac49f3d044	Worker	Conspiracy Narrative Detection - Wave 1	ACTIVE	5	80%	0.67	✗	Sept. 20, 2026, 2:28 p.m.
7b24c8e3d0f15a9b38e2c033	Worker	Conspiracy Narrative Detection - Wave 1	COMPLETED	5	100%	0.95	✗	Sept. 20, 2026, 2:28 p.m.
6a13b7d2c9e04f8a27d1b022	Worker	Conspiracy Narrative Detection - Wave 1	COMPLETED	5	80%	0.84	✗	Sept. 20, 2026, 2:28 p.m.
5f2a91c4e8b07a3d19c4e011	Worker	Conspiracy Narrative Detection - Wave 1	COMPLETED	5	100%	0.83	✗	Sept. 20, 2026, 2:28 p.m.

10 Enrollments & Assignments

Figura 4.10. Per ogni iscrizione il ricercatore vede accuratezza sulle gold unit, stato e punteggio MACE.

Il secondo meccanismo è l'integrazione di MACE (Multi-Annotator Competence Estimation) (Hovy et al. 2013), un algoritmo Expectation-Maximization che stima congiuntamente l'etichetta più probabile per ciascun documento e la competenza di ciascun annotatore, a partire dalle sole annotazioni raccolte, senza il coinvolgimento delle gold unit.

Il ricercatore lancia il calcolo MACE dalla console di amministrazione su un progetto. Il sistema produce due output distinti. Il primo è l'etichetta stimata e la confidenza associata per ogni documento, il secondo è un punteggio di competenza sull'iscrizione al progetto per ogni annotatore (§3.6). Il primo output è una stima di affidabilità complementare alle gold unit, utile dove la loro copertura è limitata; il secondo estende la valutazione dell'annotatore oltre le sole gold unit esplicite, usando l'intero volume di annotazioni raccolte.

Gold unit e MACE misurano la qualità dopo la raccolta. Quando invece qualcosa va cambiato c'è un vincolo. Una volta pubblicato ufficialmente un progetto, la sua configurazione e il suo dataset non sono più modificabili, così che tutti gli annotatori lavorino nelle stesse condizioni.

Per permettere al ricercatore di modificare un campo mentre il progetto è già pubblicato, può duplicare il progetto in tre modalità, solo configurazione, configurazione e dataset completo, oppure configurazione con le gold unit, i documenti che non hanno ancora raggiunto il numero minimo di annotazioni e gli annotatori non esclusi e non ancora completati, di cui vengono azzerate le metriche sulle gold unit, per iterare rapidamente su varianti dello studio senza ricostruire la configurazione da zero. La copia parte sempre in bozza e non pubblicata.

Stati, soglie di esclusione e parametri di distribuzione che il ricercatore osserva durante la raccolta vengono però decisi prima del lancio. La sezione seguente descrive come.

4.4 Configurazione del task

Prima che un progetto raccolga dati, il ricercatore ne definisce ogni aspetto. L'intera configurazione descritta in questo capitolo, schema, dataset, pipeline di onboarding, strategia di distribuzione, controllo qualità, è esposta attraverso un'amministrazione Django estesa, organizzata in schede tematiche: Project Details, Dataset Upload, Annotation Schema, Screening Setup, Codebook Setup, Instruction, Practice Task, Quality & Monitoring, Distribution (Figura 4.11).

The screenshot shows a web interface for project configuration. At the top, there's a breadcrumb trail: 'Annotation > Projects > Study Test #1'. To the right, there's a 'History' button and a blue circular button with a plus sign. Below this, a 'General' tab is selected, with a menu icon to its left. A horizontal navigation bar contains several tabs: 'Project Details', 'Dataset Upload', 'Annotation Schema', 'Informed Consent', 'Screening Setup', 'Codebook Setup', 'Instructions', 'Practice Task', 'Quality & Monitoring', and 'Distribution'. The 'Project Details' tab is active. It contains a blue banner for 'Playground Active (LIVE)' with a 'RETURN TO DRAFT' button. Below this, a section titled 'Project Details' explains that the user can edit the project name, slug, and description. There are two input fields: 'Name' (containing 'Study Test #1') and 'Slug' (containing 'study-test-1'). A small text below the slug field says 'Unique Identifier for the URL (e.g., 'project-slug')'. At the bottom, there's a 'Delete project' button in red, and two 'Save' buttons: 'Save and add another' and 'Save and continue editing'.

Figura 4.11. La configurazione del progetto è divisa in schede tematiche, una per ogni aspetto dello studio.

Schema, screening, codebook e istruzioni si caricano come file YAML o Markdown. Lo schema viene validato nella sua struttura e rifiutato se non conforme, il task di pratica viene bloccato se la sua soluzione non è compatibile con lo schema, mentre lo screening viene solo letto come YAML o JSON e i testi in Markdown vengono salvati così come sono. Un errore nello schema o nel task di pratica viene quindi segnalato prima che il progetto possa essere pubblicato, non scoperto a raccolta dati in corso.

Una volta che un annotatore ha superato l'onboarding (§4.2), il sistema deve decidere quali documenti assegnargli. Lo fa secondo una di tre strategie, selezionabile per progetto. La strategia standard assegna documenti in modo casuale, entro una soglia minima e massima di annotazioni per documento. La strategia a piena sovrapposizione espone a ogni annotatore l'intero dataset, per studi che richiedono la massima ridondanza. La strategia a blocchi con annotatori fissi divide il dataset in blocchi di dimensione configurabile e assegna ciascun blocco a un numero fisso di annotatori, con una ridondanza controllata. È utile quando si vuole misurare il livello di accordo tra un gruppo chiuso di annotatori sugli stessi documenti.

L'assegnazione può coinvolgere più annotatori che richiedono un documento nello stesso istante. Per questo avviene sotto lock a livello di record nel database, il documento somministrato resta bloccato per tutta la durata della transazione, così che due richieste concorrenti non ricevano mai lo stesso documento.

Una volta distribuiti, i documenti includono anche le gold unit (§3.5). Il ricercatore le carica nella stessa amministrazione e fissa i parametri del controllo qualità descritto in §4.3, cioè ogni quanti documenti iniettarne una, l'accuratezza minima richiesta e il numero di gold unit dopo cui la valutazione comincia.

Configurazione e amministrazione sono la superficie che il ricercatore vede. L'ultima sezione del capitolo scende sotto quella superficie, nell'architettura che la rende possibile.

4.5 Architettura del sistema

Interfaccia di annotazione (§4.1) e amministrazione (§4.3, §4.4) sono le due facce del sistema che rispettivamente l'annotatore e il ricercatore vedono. Quello che le rende entrambe possibili è descritto qui. Il sistema è composto da un backend Django, che espone un'API REST e la console di amministrazione, e da un frontend Vue 3 single page, che implementa l'interfaccia di annotazione. I due componenti vengono eseguiti in container Docker separati, con PostgreSQL come base dati. Il deploy dell'intero sistema avviene con un unico comando Docker Compose, per non richiedere al ricercatore competenze di configurazione infrastrutturale.




Figura 4.12. Il backend espone due piani separati, configurazione per il ricercatore ed esecuzione per l'annotatore, entrambi alimentati dallo stesso schema di annotazione.

L'architettura, schematizzata in Figura 4.12, separa nettamente due piani, il primo quello di configurazione, esposto tramite la dashboard di amministrazione Django, rivolto al ricercatore e ai suoi collaboratori, e il secondo di esecuzione, esposto tramite API REST e rivolto all'annotatore. Configurare l'annotazione e comporla non richiedono le stesse competenze, né la stessa superficie di rischio, e vanno perciò esposte separatamente. I due piani condividono un solo punto di verità, lo schema di annotazione del progetto (§3.3), che alimenta sia la validazione lato configurazione sia la generazione dell'interfaccia lato esecuzione. Un cambiamento allo schema si riflette in entrambi senza sincronizzazione manuale.

Backend, frontend e i due piani che espone sono l'infrastruttura su cui si appoggia

tutto quello che il capitolo ha descritto finora. Con questo il capitolo chiude la descrizione dei meccanismi che realizzano i concetti del capitolo precedente (§3). Il capitolo Risultati ne valuta il funzionamento messo alla prova.

Capitolo 5

Risultati

5.1 La valutazione con un'esperta di dominio

Le prove descritte finora dicono che il sistema funziona, ma non dicono se chi deve usarlo riesce a capirlo. Un ricercatore che prepara uno studio di annotazione non legge il codice, attraversa l'interfaccia una schermata alla volta e decide cosa fare in base a quello che vede. Se un'etichetta è ambigua o un'opzione sta nel posto sbagliato, il rischio non è un errore del software ma un progetto configurato male, oppure un'azione irreversibile compiuta senza volerlo. Per osservare questo lato del sistema serve una persona che lo usi davvero. Questa sezione racconta la sessione condotta con una ricercatrice che conosce il problema dall'interno, cosa ne è emerso e come il sistema è cambiato di conseguenza.

5.1.1 Perché un cognitive walkthrough, e con chi

Il metodo scelto è il cognitive walkthrough (Wharton et al. 1994), una tecnica di ispezione dell'usabilità pensata per chi usa un sistema per la prima volta. Il valutatore percorre una sequenza di task realistici e, per ogni passo, si chiede se l'utente capirebbe cosa deve fare, se troverebbe il comando giusto, se ne interpreterebbe correttamente l'etichetta e se, dopo averlo usato, si accorgerebbe di aver ottenuto l'effetto voluto. Il metodo si adatta bene a una piattaforma come questa, dove la maggior parte delle difficoltà nasce proprio dal primo contatto, quando chi configura un progetto deve orientarsi tra molte opzioni senza ancora conoscere le regole del sistema.

La sessione si è svolta il 16 aprile 2026, da remoto, ed è durata tra un'ora e un'ora e mezza. La partecipante è Veronika Batzdorfer, tra gli organizzatori di PsyCoMark (Samory, Soldner e Batzdorfer 2026), quindi una persona che ha già condotto in prima persona uno studio di annotazione in crowdsourcing simile a quello che la piattaforma vuole supportare. Non aveva mai usato l'interfaccia, ma conosceva già alcune delle funzionalità per averne discusso in precedenza con il relatore. È un profilo utile proprio per questo, perché unisce la freschezza di chi vede le schermate per la prima volta alla competenza di chi sa cosa serve davvero a un ricercatore.

La traccia della sessione comprendeva sette task, che coprono l'intero ciclo di vita di un progetto.

1. Creare un nuovo progetto.
2. Caricare il dataset da annotare.
3. Portare il progetto nell'ambiente di prova (*Live (playground)*).
4. Simulare un partecipante e completare un'annotazione di prova.
5. Cancellare i dati di prova senza toccare il progetto.
6. Lanciare ufficialmente il progetto.
7. Correggere un errore nella configurazione di un progetto già lanciato.

Rispetto alla forma classica del metodo, la sessione ha preso una piega più guidata. Era il candidato a condividere lo schermo e a muoversi nell'interfaccia seguendo la traccia, mentre la partecipante osservava, commentava ad alta voce e interrompeva con domande ogni volta che qualcosa non le era chiaro. Questa scelta riduce la possibilità di osservare dove l'utente si perde da solo, ma in cambio ha lasciato spazio a domande che la traccia non prevedeva, e alcune di queste si sono rivelate le più utili. Della sessione esiste una registrazione di circa ventisei minuti, che copre la seconda parte del percorso, dall'annotazione di prova alla clonazione del progetto e al monitoraggio. Le osservazioni sui primi task vengono invece dagli appunti presi durante la sessione.


Con il contesto chiarito, le osservazioni si possono leggere per temi invece che task per task, perché diversi problemi si ripresentano in punti diversi del percorso.

5.1.2 Cosa è emerso

Le osservazioni si raccolgono in quattro gruppi. Due riguardano problemi veri e propri, cioè la struttura della configurazione e la chiarezza di alcune etichette. Il terzo riguarda il modo in cui il sistema gestisce le azioni irreversibili, dove il design ha retto ma ha comunque generato domande. L'ultimo raccoglie un'esigenza che il sistema non copriva affatto.

Il dataset si nascondeva in fondo alla pagina. Il primo ostacolo è comparso già nei task iniziali. All'epoca la configurazione era divisa in sei schede, ma alcune raccoglievano più aspetti diversi. La scheda *Annotation schema & Dataset upload* metteva insieme lo schema di annotazione e il caricamento dei documenti, e il campo per il file del dataset compariva solo in fondo, dopo l'intero schema in YAML (Figura 5.1, a sinistra). Chi arrivava sulla scheda vedeva lo schema e non trovava il punto in cui caricare i dati se non scorrendo. La partecipante ha faticato proprio qui, e il problema non riguarda un singolo pulsante. Una pagina che unisce cose diverse non comunica la struttura del lavoro da fare.

La configurazione è stata quindi riorganizzata in dieci schede, una per ciascun aspetto del progetto. Il caricamento del dataset ha ora una scheda propria, separata dallo schema (Figura 5.1, a destra), e lo stesso è avvenuto per le schede che univano più passaggi dell'onboarding, divise in consenso informato, screening, codebook, istruzioni e task di prova. Oltre a rendere ogni campo visibile senza scorrere, l'ordine delle schede suggerisce anche l'ordine in cui conviene procedere.



(a) Prima della sessione. Schema e dataset nella stessa scheda, con il caricamento dei documenti in fondo. (b) Dopo la sessione. Il caricamento del dataset ha una scheda dedicata.

Figura 5.1. La configurazione del progetto prima e dopo il cognitive walkthrough.

Alcune etichette dicevano meno di quanto sembrava. Durante l'annotazione di prova, mentre selezionava gli span, la partecipante ha chiesto se esistesse un modo per tornare indietro. Il sistema offre due strade, la X sul singolo span e un pulsante *Clear*, ma proprio quest'ultimo l'ha lasciata in dubbio, perché non era chiaro se cancellasse l'ultimo span o tutti. Ha suggerito lei stessa di chiamarlo *Clear all*, e l'etichetta è stata cambiata in questo senso (Figura 5.2). Sull'assenza di una scorciatoia per annullare l'ultima azione ha invece osservato che non è un problema rilevante. È un esempio piccolo, ma mostra quanto il significato di un'etichetta dipenda dal contesto in cui compare, perché la stessa parola che altrove sarebbe ovvia diventa ambigua quando sullo schermo convivono più span sovrapposti.

Le azioni irreversibili hanno retto, ma hanno fatto nascere domande. Il ciclo di vita del progetto è la parte in cui un errore costa di più, e infatti è quella in cui la partecipante si è fermata più spesso a chiedere. Vedendo il pulsante di lancio ufficiale, la prima domanda è stata cosa succede se si lancia per errore e si vuole togliere il progetto dalla rete. La risposta esiste, perché un progetto lanciato può essere messo in pausa, ma il fatto che la domanda sia arrivata subito conferma che il timore dell'irreversibilità è reale, e giustifica la scelta di isolare queste azioni in una zona separata dell'interfaccia. Un secondo punto ha riguardato la cancellazione dei dati di prova, che richiede di riportare prima il progetto in bozza o in pausa. Il sistema lo comunica con un messaggio, ma solo dopo che l'utente ha provato, quindi il vincolo si scopre per tentativi. Infine il blocco della configurazione dopo il lancio è stato capito senza difficoltà. Il banner che spiega perché i campi non sono più modificabili e propone di clonare il progetto (Figura 5.3) è risultato chiaro, e lo stesso vale per la differenza tra clonare solo la configurazione o anche documenti e annotatori. È un risultato che conta, perché il task 7 era quello in cui l'utente si

Task Instruction
Highlight the psycholinguistic markers, then select the overall classification.

HIGHLIGHTER Actor 1 Action 2 Effect 3 Victim 4 Evidence 5

They keep telling us the new vaccine rollout is about public health, but the pharma companies and the government planned this years ago. They are hiding the side effects from ordinary families so that they can track everyone. Look at the leaked documents from last spring, it is all there if you read them.

Classify this text:

☒ Conspiracy

☐ Not Conspiracy

☐ Ambiguous

Figura 5.2. L'interfaccia di annotazione dopo la sessione. Con più span sovrapposti sullo stesso testo, il pulsante in basso dichiara esplicitamente che rimuove tutte le annotazioni del documento.

trova davanti a un vicolo cieco, e il banner è riuscito a indicargli l'uscita.

Un'esigenza che il sistema non copriva. L'osservazione più importante non riguardava nessuno dei sette task. Guardando quanto velocemente si poteva completare un'annotazione di prova, la partecipante ha chiesto se fosse possibile imporre un tempo minimo per ogni documento, così da impedire che un partecipante clicchi a caso, completi il compito in pochi secondi e venga comunque pagato. È un problema concreto di chi lavora in crowdsourcing, ed è lo stesso che i meccanismi di controllo qualità descritti nel capitolo 4 affrontano solo a posteriori. Oggi il sistema registra il tempo impiegato per ogni annotazione e, nella vista amministrativa, evidenzia in rosso quelle completate in meno di cinque secondi, ma non impedisce l'invio. Il ricercatore può quindi accorgersi del comportamento e intervenire, ad esempio escludendo l'annotatore dalla distribuzione, ma non può prevenirlo. Questa lacuna resta aperta ed è ripresa nel capitolo sulle limitazioni.

Accanto a questi problemi, la sessione ha fatto emergere anche ciò che funziona, e conviene riportarlo con la stessa cura.

5.1.3 Cosa ha convinto

Gli apprezzamenti si sono concentrati sulle parti che aiutano il ricercatore a controllare il proprio studio prima e durante la raccolta. La partecipante ha indicato come particolarmente utile l'ambiente di prova, che permette di attraversare il percorso da partecipante e verificare che la configurazione sia corretta prima di aprire il progetto al pubblico. Ha apprezzato la vista della singola annotazione, sia nella resa grafica

The screenshot shows a web interface for project management. At the top, there are tabs for 'General', 'Project Members', and 'Project Log Entries'. Below these, a sub-header contains 'Project Details' (active), 'Dataset Upload', 'Annotation Schema', 'Informed Consent', 'Screening Setup', 'Codebook Setup', 'Instructions', and 'Practice Task'. Under 'Project Details', there are links for 'Quality & Monitoring' and 'Distribution'. A yellow banner with a lock icon states 'Official Project & Locked' and explains that the configuration is sealed for data integrity, with a 'CLONE PROJECT' button. Below the banner, a 'Project Details' section allows editing the project name, slug, and description. The fields are as follows:

Field	Value
Name	[DEMO] Conspiracy Theory Detection Project name
Slug	demo-live-conspiracy Unique Identifier for the URL (e.g., 'project-slug')
Description	Active annotation campaign for detecting conspiracy theories in social media posts. Annotators highlight key spans and classify each post. Project description

Figura 5.3. Un progetto lanciato ufficialmente. I campi sono in sola lettura e il banner spiega il motivo, proponendo la clonazione come via per apportare modifiche.

sia nel formato grezzo, il calcolo dell'affidabilità degli annotatori, che ha definito *really handy*, e il registro delle attività, utile soprattutto quando sullo stesso progetto lavorano più ricercatori. Il giudizio complessivo è stato positivo, con un riferimento esplicito alla quantità di aspetti personalizzabili e alla loro sensatezza.

L'unica critica di fondo riguarda proprio questa ricchezza. Secondo la partecipante, per chi non ha mai visto la dashboard e la pipeline completa le informazioni sono tante. È un'osservazione coerente con il problema della pagina unica descritto sopra, e la riorganizzazione in sottosezioni ne è in parte la risposta, ma la curva di apprendimento iniziale resta un aspetto su cui il sistema può migliorare.

5.1.4 Dalle osservazioni agli interventi

La tabella 5.1 riassume le osservazioni principali e il modo in cui il sistema è cambiato dopo la sessione.

Tra le osservazioni in tabella, una merita di essere ripresa. Il tempo minimo per documento sembra un'esigenza isolata, ma riporta a un problema già incontrato in questo capitolo da tutt'altra strada.

5.1.5 Due prove, la stessa debolezza

Nello studio simulato (§6.3) l'annotatore con il profilo da spammer risponde sempre con la stessa classe. Proprio per questo supera la soglia di accuratezza sulle gold unit e non viene escluso, mentre MACE, guardando l'insieme delle sue risposte, gli attribuisce la competenza più bassa del gruppo. La domanda di Veronika Batzdorfer descrive lo stesso comportamento visto dal lato umano. Chi partecipa a uno studio retribuito può attraversare i documenti in fretta, senza leggerli davvero, e arrivare comunque al codice di completamento. La sua preoccupazione non nasceva da un'ipotesi, ma dall'esperienza di chi ha raccolto in crowdsourcing le annotazioni di PsyCoMark.

Le due prove sono indipendenti. La prima viene da annotatori artificiali costruiti apposta, la seconda da una ricercatrice che non conosceva i loro profili. Arrivano

Osservazione	Intervento
Schema e dataset nella stessa scheda, con il caricamento dei documenti visibile solo scorrendo	Configurazione riorganizzata in dieci schede, con il dataset in una scheda dedicata
Il pulsante <i>Clear</i> non chiarisce se cancella uno o tutti gli span	Etichetta cambiata in <i>Clear all</i>
Timore di non poter ritirare un progetto lanciato per errore	Nessuno, la pausa copre il caso e la zona separata per le azioni irreversibili è confermata
La cancellazione dei dati di prova richiede lo stato di bozza o pausa, scoperto solo per tentativi	Il vincolo è comunicato da un messaggio al momento del tentativo
Blocco della configurazione dopo il lancio e opzioni di clonazione	Nessuno, risultati chiari
Nessun modo di imporre un tempo minimo per documento	Solo monitoraggio, con le annotazioni sotto i cinque secondi evidenziate, questione rimandata alle limitazioni

Tabella 5.1. Osservazioni emerse dal cognitive walkthrough e interventi conseguenti.

però allo stesso punto, cioè che il controllo basato sulle gold unit ferma chi sbaglia, ma non chi lavora senza impegnarsi e ha la fortuna, o l'accortezza, di rispondere in modo compatibile con le soluzioni attese. Il sistema raccoglie già i segnali che permettono di riconoscere questo comportamento, la competenza stimata da MACE e il tempo impiegato per ogni documento, ma li usa solo per il monitoraggio a posteriori. Nessuno dei due interviene mentre la raccolta è in corso.

Questa convergenza dà alla debolezza un peso maggiore di quello che avrebbe se fosse emersa da una sola delle due prove, e indica anche una direzione concreta. Un controllo di qualità più robusto non ha bisogno di nuovi dati, ma di usare in tempo reale quelli che il sistema già raccoglie. Il capitolo di discussione riprende questo punto.

5.1.6 In sintesi

Nel complesso la sessione ha spostato l'attenzione da come il sistema funziona a come viene capito. I problemi emersi non riguardano la logica della piattaforma, che ha retto anche nelle parti più delicate, ma il modo in cui questa logica viene presentata a chi la incontra per la prima volta. Resta il limite di una valutazione condotta con una sola esperta e in forma guidata, che non sostituisce uno studio con più utenti, e su cui si torna nel capitolo sulle limitazioni. Il capitolo successivo riprende questi risultati insieme a quelli dello studio simulato, per capire cosa dicono, nel loro insieme, rispetto al problema da cui la tesi è partita.

Capitolo 6

Discussione

Il capitolo precedente ha descritto cosa è successo quando il sistema è stato messo alla prova, con i test automatici, con lo studio simulato e con la sessione insieme a un'esperta di dominio. Questo capitolo prova a dire cosa significano quei risultati. Per ogni aspetto si chiede se il sistema si è comportato come ci si aspettava, dove invece ha sorpreso, e cosa ne segue per il problema da cui la tesi è partita. Si parte dalle aspettative, si passa alle parti che i risultati confermano e a quelle in cui se ne discostano, e si chiude con ciò che i risultati dicono, e non dicono, sul gap dichiarato nell'introduzione.

6.1 Le aspettative di partenza

La tesi nasce da un'osservazione precisa. Gli strumenti di annotazione esistenti trattano gli span sovrapposti come un'estensione del formato dati e non come un'esperienza progettata per chi annota, e chi conduce uno studio in crowdsourcing deve comporre a mano più strumenti per coprire l'intero ciclo, dal reclutamento all'analisi dell'affidabilità. Il sistema risponde con due proposte, un'interfaccia pensata per definire span sovrapposti direttamente sul testo e una piattaforma che integra in un'unica configurazione tutte le fasi dello studio.

Da queste proposte discendono tre aspettative, che fanno da filo conduttore per il resto del capitolo. La prima è che il ciclo dello studio regga da capo a fondo senza strumenti esterni. La seconda è che il controllo qualità distingua chi lavora bene da chi no. La terza è che un ricercatore riesca a orientarsi nella configurazione e nel ciclo di vita di un progetto senza conoscere il codice. Le sezioni seguenti le riprendono una alla volta.

6.2 L'integrazione del ciclo regge

La prima aspettativa è quella confermata in modo più netto. Nello studio simulato dieci annotatori hanno attraversato l'intero percorso passando dagli endpoint reali del sistema, dal consenso informato fino al codice di completamento. In tutte e trenta le ripetizioni la distribuzione ha portato i venti documenti oltre la soglia minima di tre annotazioni, con un totale compreso tra 140 e 146 annotazioni. Le gold unit sono state iniettate e valutate, gli annotatori sotto soglia sono stati esclusi

in modo automatico e MACE ha stimato competenze ed etichette sui dati raccolti. Nessuna di queste fasi ha richiesto di esportare dati, convertirli o passarli a un altro strumento.

La sessione con l'esperta di dominio conferma lo stesso punto dal lato di chi usa il sistema. Le funzionalità che Veronika Batzdorfer ha indicato come più utili sono l'ambiente di prova, il calcolo dell'affidabilità e il registro delle attività condiviso tra ricercatori. Sono proprio le parti che, componendo strumenti separati, vanno costruite o raccordate a mano. È la risposta più diretta alla domanda su cosa offra il sistema rispetto a uno strumento generalista come Potato. Il valore non sta in una singola funzione, ma nel fatto che le fasi dello studio condividono la stessa configurazione e gli stessi dati.

Fin qui i risultati confermano le aspettative. Il controllo qualità, invece, ha mostrato un comportamento diverso da quello previsto, ed è il punto su cui conviene soffermarsi di più.

6.3 Il controllo qualità

Il sistema affida il controllo qualità a due meccanismi, le gold unit, che decidono in tempo reale se escludere un annotatore, e MACE, che stima a posteriori la competenza di ciascuno. Ci si aspettava che i due meccanismi arrivassero a conclusioni simili. Lo studio simulato, ripetuto trenta volte con semi casuali diversi, mostra invece che possono divergere molto, e che la divergenza dice qualcosa su come vanno configurati. I numeri che seguono sono frequenze sulle trenta ripetizioni e non valori di una singola esecuzione, perché da un'esecuzione all'altra gli esiti individuali cambiano in modo sensibile. La Tabella 6.1 ne riassume gli esiti per profilo di annotatore.

Profilo	n	Esclusi	Acc. gold	Acc. reale	MACE	MACE min-max
Esperto	90	2 (2%)	94%	94%	0,868	0,463–0,951
Buono	90	12 (13%)	81%	87%	0,754	0,294–0,951
Medio	30	5 (17%)	80%	77%	0,633	0,168–0,947
Sciatto	60	37 (62%)	49%	55%	0,333	0,020–0,791
Spammer	30	10 (33%)	61%	33%	0,032	0,022–0,060

Tabella 6.1. Esiti del controllo qualità per profilo di annotatore, aggregati su 30 ripetizioni dello studio simulato. n è il numero di annotatori di quel profilo sommato sulle ripetizioni. L'accuratezza sulle gold unit è quella usata dal sistema per decidere l'esclusione, l'accuratezza reale è calcolata sulle etichette previste dei documenti regolari, e MACE riporta la competenza stimata media.

Le gold unit da sole non bastano. Il caso più chiaro è quello dello spammer, un annotatore simulato che risponde sempre con la stessa classe. Su trenta ripetizioni non viene escluso in venti casi, pur avendo un'accuratezza reale media del 33%, cioè quella del caso. La ragione è semplice. Lo spammer viene valutato dopo tre gold unit, e quando due delle tre appartengono alla classe che sceglie sempre ottiene il 67%, sopra la soglia del 60%. Lo stesso problema si vede in senso opposto. In dodici ripetizioni su trenta almeno un annotatore con profilo esperto o buono viene escluso,

per un totale di quattordici esclusioni ingiustificate. Su tre gold unit un solo errore porta l'accuratezza al 67%, due errori la portano al 33%, e basta un po' di sfortuna per far uscire un annotatore valido. Nel complesso, quasi metà dei profili inaffidabili, 43 su 90 tra sciatti e spammer, arriva in fondo alla raccolta senza essere esclusa.

Da questi casi seguono tre indicazioni per chi configura uno studio. La soglia va tarata sul numero di classi, perché con tre opzioni il caso produce già circa il 33% di risposte corrette. Le gold unit vanno bilanciate tra le classi, così che nessuna risposta costante possa superare la soglia. Infine, il numero minimo di gold unit prima di valutare un annotatore va scelto tenendo conto di quanto sia rumorosa la stima su pochi elementi. Il sistema rende già configurabili tutti questi parametri. Quello che lo studio aggiunge è la prova che i valori predefiniti non sono neutri.

MACE vede ciò che le gold unit non vedono, ma non è un oracolo. MACE attribuisce allo spammer la competenza più bassa del gruppo in 27 ripetizioni su 30, con un valore medio di 0,03, e ricostruisce in media 19,6 etichette corrette su 20. È il comportamento atteso da un metodo che sfrutta tutte le annotazioni raccolte invece di pochi documenti di controllo. Due risultati però invitano a non considerarlo una verità di riferimento. Il primo è che la competenza stimata per lo stesso profilo varia molto tra le ripetizioni. Per gli annotatori con profilo buono va da 0,29 a 0,95, perché con una decina di documenti per annotatore anche MACE lavora su pochi dati. Il secondo è che la sua confidenza non segnala in modo affidabile i propri errori. Delle tredici etichette sbagliate nelle trenta ripetizioni, quattro hanno una confidenza pari o superiore a 0,9, e tredici etichette corrette hanno invece una confidenza inferiore a 0,6.

Due prove indipendenti arrivano allo stesso punto. La debolezza delle gold unit non emerge solo dalla simulazione. Durante il cognitive walkthrough l'esperta di dominio ha chiesto se fosse possibile imporre un tempo minimo per documento, così da fermare chi risponde in fretta e senza leggere pur di ottenere il compenso. È lo stesso comportamento dello spammer, visto dal lato di chi ha già condotto uno studio reale. Le due prove convergono su una conclusione. Il controllo con le gold unit ferma chi sbaglia, ma non chi lavora senza impegnarsi e risponde in modo compatibile con le soluzioni attese.

Il sistema raccoglie già due segnali che permettono di riconoscere questo comportamento, la competenza stimata da MACE e il tempo impiegato per ogni documento. Oggi però li usa solo per il monitoraggio a posteriori. La direzione che i risultati indicano non richiede quindi nuovi dati, ma di usare durante la raccolta quelli che il sistema già possiede, ad esempio ricalcolando MACE a intervalli regolari o segnalando gli annotatori con tempi anomali.

Il controllo qualità mostra che una configurazione sbagliata può compromettere lo studio. La sezione seguente mostra che lo stesso vale, in modo più sottile, per la configurazione nel suo insieme.

6.4 Una configurazione unica sposta il rischio

Integrare tutte le fasi in un'unica configurazione elimina il lavoro di raccordo tra strumenti diversi, ed è uno dei vantaggi del sistema. Lo studio simulato ha mostrato il rovescio di questa scelta. Durante la preparazione dello studio, in una prova precedente, un annotatore che aveva risposto correttamente a tutte le gold unit è stato escluso con accuratezza nulla. Lo schema di annotazione associava a ogni opzione un'etichetta visibile e un valore interno, ad esempio *Conspiracy* e *Yes*, e l'interfaccia inviava il valore. Le soluzioni delle gold unit, invece, erano state scritte usando l'etichetta. Il confronto tra le due stringhe falliva sempre. La validazione delle soluzioni esisteva, ma veniva saltata quando le gold unit erano caricate prima che lo schema fosse attivo.

Il difetto in sé è piccolo, ma il suo effetto non lo è, perché un errore in un solo file di configurazione si è propagato fino all'esclusione di un annotatore valido. Quando le fasi dello studio condividono la stessa configurazione, un errore in quella configurazione non resta confinato in un punto. Il rischio non scompare, si sposta dal raccordo tra strumenti alla coerenza interna della configurazione. Ne segue che, in un sistema integrato, la validazione incrociata tra le parti della configurazione, come schema e soluzioni delle gold unit, va trattata come una funzione centrale e non come un controllo accessorio. In questo senso l'ambiente di prova, che Veronika Batzdorfer ha indicato come la funzione più utile, ha un ruolo più importante di quanto sembri, perché è il luogo in cui il ricercatore può accorgersi di questi errori prima che coinvolgano annotatori reali.

Le sezioni precedenti riguardano soprattutto la piattaforma. Resta da capire cosa dicono i risultati sull'altra proposta della tesi, l'interfaccia per gli span sovrapposti.

6.5 Cosa i risultati dicono sul gap

Il gap da cui la tesi parte riguarda l'esperienza dell'annotatore davanti a span sovrapposti. I risultati raccolti sostengono questa parte della tesi in modo indiretto. Durante il cognitive walkthrough l'unica ambiguità emersa nell'interfaccia di annotazione è legata proprio alla sovrapposizione. Con più span sullo stesso testo, il pulsante *Clear* non chiariva se rimuovesse l'ultimo span o tutti. In un'interfaccia con un solo span per porzione di testo la stessa parola non creerebbe dubbi. È un episodio piccolo, ma va nella direzione del gap. L'overlap pone problemi di interazione propri, che un formato dati da solo non risolve e che vanno affrontati con scelte di interfaccia mirate.

Va però detto con chiarezza cosa i risultati non mostrano. Il vantaggio dell'interfaccia rispetto a Potato è argomentato nel capitolo dei metodi, a partire dal confronto tra le due interazioni, ma non è misurato. Nessuno dei test svolti coinvolge annotatori reali che definiscono span sovrapposti, e quindi la tesi non dispone di dati su errori di confine, tempi di annotazione o accordo tra annotatori. Gli annotatori dello studio simulato producono span secondo regole fissate in anticipo, e servono a verificare il comportamento del sistema, non quello delle persone. La parte della tesi che riguarda l'integrazione del ciclo è quindi sostenuta dai risultati, mentre quella che riguarda l'interazione con gli span sovrapposti resta una proposta motivata, in

attesa di una verifica sperimentale. Il capitolo sulle limitazioni torna su questo punto e descrive lo studio che servirebbe.

C'è infine un aspetto che riguarda tutti e due i meccanismi di controllo qualità e che tocca la motivazione stessa del lavoro.

6.6 Una tensione con il perspectivismo

Sia le gold unit sia MACE assumono che ogni documento abbia una sola risposta corretta. Le gold unit la dichiarano in anticipo, MACE la stima a partire dalle annotazioni, ma in entrambi i casi un annotatore che si discosta dalla risposta maggioritaria viene trattato come meno affidabile. Il paradigma perspectivista, richiamato nell'introduzione, mette in discussione proprio questa assunzione e considera il disaccordo tra annotatori un'informazione legittima, che riflette differenze di esperienza e di interpretazione (Cabitza, Campagner e Basile 2023). Per un compito come il riconoscimento di narrative complottiste, dove la stessa frase può essere letta in modi diversi da persone diverse, la questione non è teorica.

Lo studio simulato ne offre un indizio. Delle tredici etichette su cui MACE si discosta da quella prevista, otto coinvolgono la classe *Can't tell*, assegnata a documenti che il disegno dello studio considerava netti o, al contrario, negata a documenti pensati come ambigui. Nella simulazione il disaccordo è rumore per costruzione, perché gli annotatori artificiali sbagliano a caso. In uno studio reale, però, gli stessi numeri non permetterebbero di stabilire se si tratti di un errore della stima o di un'ambiguità effettiva del testo, che lettori diversi risolvono in modi diversi. Il sistema, così com'è, offre al ricercatore gli strumenti per misurare la qualità rispetto a una risposta unica, ma non per distinguere il rumore dal disaccordo informativo. È una scelta coerente con la pratica corrente nel crowdsourcing, ma va resa esplicita, perché un controllo qualità troppo severo rischia di escludere proprio le prospettive minoritarie che il paradigma perspectivista vorrebbe conservare.

6.7 In sintesi

Dei tre aspetti da cui si era partiti, i risultati confermano il primo e il terzo. Il ciclo dello studio regge senza strumenti esterni, e un'esperta di dominio riesce a orientarsi nel sistema, con difficoltà che riguardano la presentazione e non la logica. Il secondo, il controllo qualità, funziona ma in modo diverso dal previsto. Le gold unit da sole lasciano passare comportamenti scorretti, MACE li individua ma non è infallibile, e i parametri predefiniti vanno tarati sul singolo studio. Due ulteriori lezioni riguardano il disegno del sistema. Una configurazione unica sposta il rischio sulla sua coerenza interna, e un controllo qualità fondato su una risposta corretta unica è in tensione con un dominio in cui il disaccordo può essere informativo. Sul gap, i risultati sostengono la proposta di integrazione e offrono un indizio a favore di quella sull'interfaccia, che però resta da misurare. Il capitolo successivo discute i limiti di queste conclusioni e il lavoro che servirebbe per superarli.

Capitolo 7

Limitazioni e Sviluppi Futuri

Capitolo 8

Conclusioni

Bibliografia

- Cabitza, Federico, Andrea Campagner e Valerio Basile (2023). «Toward a Perspectivist Turn in Ground Truthing for Predictive Computing». In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 37. 6, pp. 6860–6868. DOI: 10.1609/aaai.v37i6.25840.
- Hovy, Dirk et al. (2013). «Learning Whom to Trust with MACE». In: *Proceedings of the 2013 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Association for Computational Linguistics, pp. 1120–1130. URL: <https://aclanthology.org/N13-1132/>.
- Klie, Jan-Christoph et al. (2018). «The INCEpTION Platform: Machine-Assisted and Knowledge-Oriented Interactive Annotation». In: *Proceedings of the 27th International Conference on Computational Linguistics: System Demonstrations*. Association for Computational Linguistics, pp. 5–9. URL: <https://aclanthology.org/C18-2002/>.
- Montani, Ines e Matthew Honnibal (2018). *Prodigy: A New Annotation Tool for Radically Efficient Machine Teaching*. Explosion. URL: <https://prodi.gy>.
- Nakayama, Hiroki et al. (2018). *doccano: Text Annotation Tool for Human*. Software. URL: <https://github.com/doccano/doccano>.
- Neves, Mariana e Jurica Ševa (2021). «An Extensive Review of Tools for Manual Annotation of Documents». In: *Briefings in Bioinformatics* 22.1, pp. 146–163. DOI: 10.1093/bib/bbz130.
- Pei, Jiaxin et al. (2022). «POTATO: The Portable Text Annotation Tool». In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. Association for Computational Linguistics, pp. 327–337. URL: <https://aclanthology.org/2022.emnlp-demos.33/>.
- Samory, Mattia, Felix Soldner e Veronika Batzdorfer (2026). «SemEval-2026 Task 10: PsyCoMark – Psycholinguistic Conspiracy Marker Extraction and Detection». In: *Proceedings of the 20th International Workshop on Semantic Evaluation (SemEval-2026)*. Association for Computational Linguistics. URL: <https://aclanthology.org/2026.semeval-1.444/>.
- Tkachenko, Maxim et al. (2020). *Label Studio: Data Labeling Software*. Open source software. URL: <https://github.com/HumanSignal/label-studio>.
- Wharton, Cathleen et al. (1994). «The Cognitive Walkthrough Method: A Practitioner’s Guide». In: *Usability Inspection Methods*. A cura di Jakob Nielsen e Robert L. Mack. New York: John Wiley & Sons, pp. 105–140.

